

Sesión 1
Introducción

Docente: Soledad Espezua Llerena

s.espezual@up.edu.pe

Objetivos de la clase de hoy

- Reconocer el proceso KDD y la metodología CRISP-DM.
- Identificar tipos de problemas de minería de datos: segmentación, reducción dimensional, asociación, recomendación y anomalías.
- Relacionar estos problemas con posibles proyectos aplicados.

Minería de datos

Proceso sistemático de **extraer patrones, tendencias y relaciones** a partir de grandes bases de datos para **apoyar predicciones y decisiones de negocio**, aprovechando métodos de **IA, aprendizaje automático, estadística** y **sistemas de bases de datos.**

Es la **búsqueda** de información valiosa en grandes volúmenes de datos.

(Weiss S. M., 1997)

Es el análisis de conjuntos de datos de observación (generalmente grandes) para encontrar **relaciones desconocidas** en nuevas formas que sean comprensibles y **útiles** para el propietario de los datos.

(Hand D., 2001)

Busca grandes cantidades de datos para determinar **patrones** que de otro modo se "perderían en el ruido".

(Conrad E., 2016)

Proceso de descubrimiento de **patrones** y **relaciones** a partir de grandes volúmenes de datos, con el fin de generar conocimiento relevante.

(Modelos generativos de lenguaje, 2026)

Fayyad, U. M., Piatetsky-Shapiro, G., & Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine, 17*(3), 37–54.

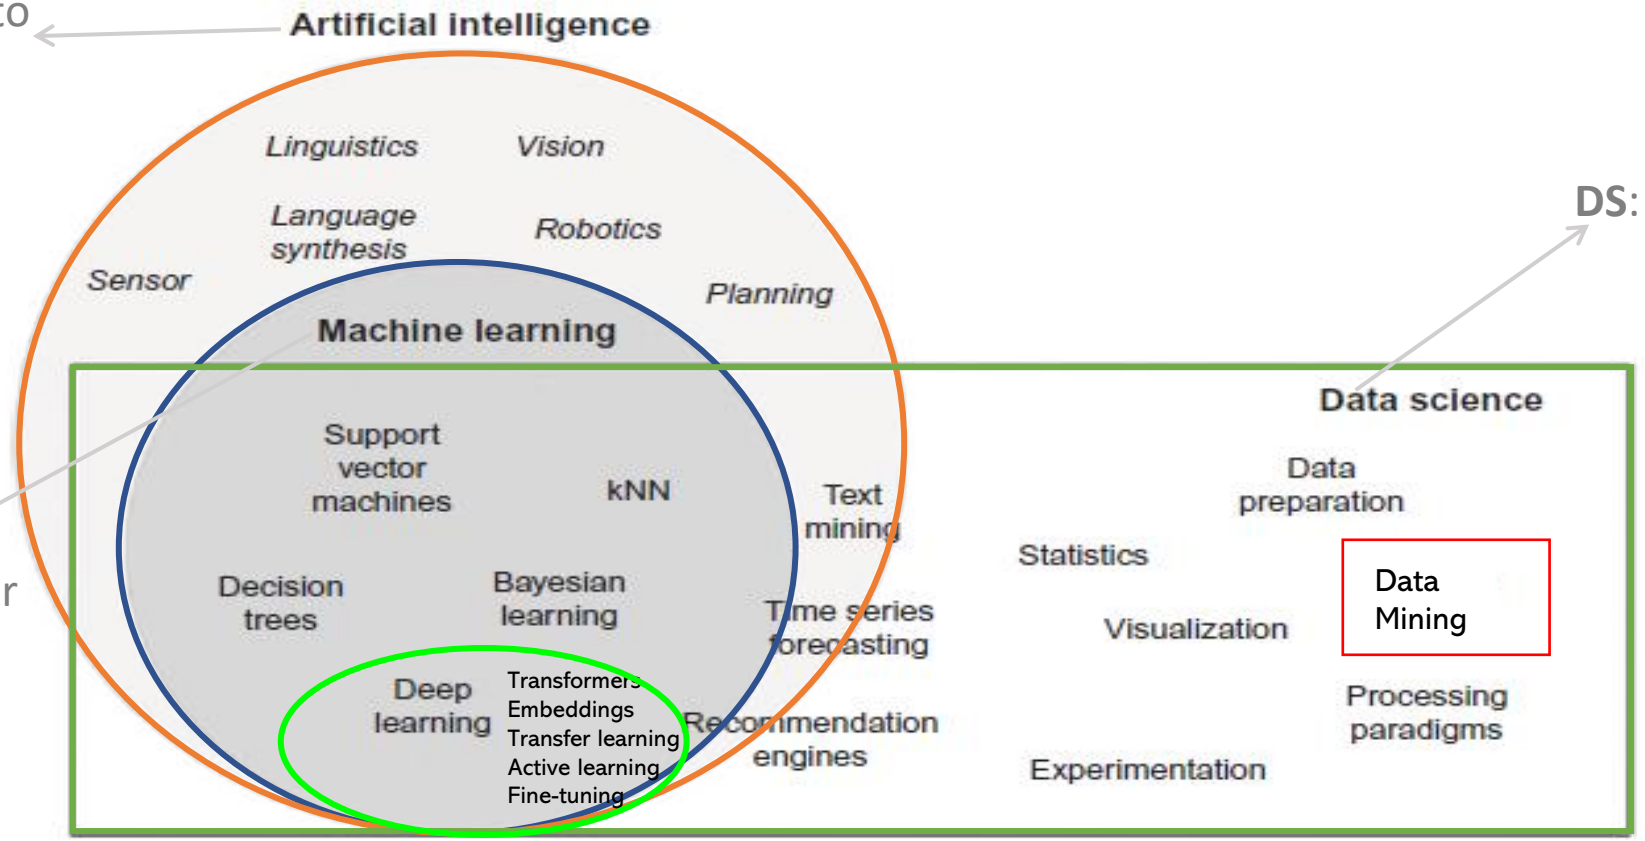
Han, J., Kamber, M., & Pei, J. (2011). *Data mining: Concepts and techniques* (3rd ed.). Morgan Kaufmann.

Weiss S. M. and Indurkhya N. (1997). Predictive Data Mining: A Practical Guide, 1st Edition.The Morgan Kaufmann Series in Data Management Systems.

Conrad E. Misenar E. and Feldman J. (2016). CISSP Study Guide, Third Edition.

Data science vs Artificial Intelligence vs Machine learning

IA: imitar comportamiento humano



DS: extraer valor de los datos

ML: aprender a partir de la "experiencia" (datos)

Adaptado de Kotu, Vijay and Deshpande, Bala (2018*). Data Science: Concepts and Practice.* Edition 2

De los datos a la sabiduría



Figura adaptada y texto resumido a partir de Butka, Bednár e Ivančáková (2020).

Sabiduría: usar el conocimiento para agregar valor o recomendar acciones.

Conocimiento: entender la información (causas, reglas, patrones y procedimientos, que conducen a decisiones y acciones).

Información: obtener datos con interpretación y significado agregados (datos formateados, filtrados y resumidos).

Datos: números, imágenes, audio u otra fuente sin procesar que generalmente describe objetos del mundo real.

Butka, P., Bednár, P., & Ivančáková, J. (2020). *Methodologies for Knowledge Discovery Processes in Context of AstroGeoInformatics*. In P. Škoda (Ed.), *Knowledge Discovery in Big Data from Astronomy and Earth Observation* (pp. 1–20). Elsevier.

De los datos a la sabiduría









Datos →	Información →	Conocimiento →	Sabiduría
BD (Ventas del 2018 al 2023)	Tendencia de ventas por año	Se entiende que la nueva línea de ropa deportiva lanzada en 2020, ayudó a aumentar las ventas	Decidir expandir esa línea de productos a más tiendas
Texto (Noticias o publicaciones en redes sociales)	Identificación de sentimientos (+,-), temas, entidades mencionadas, emociones, intención, sesgo	Se comprende cómo reacciona la población frente a un evento y qué temas le preocupan	Tomar mejores decisiones de comunicación o hacer recomendaciones
Séries temporales de sensores (Mediciones de sensores)	Detección de niveles o tendencias de contaminación	Se entienden las posibles causas de esos cambios	Aplicar medidas preventivas o proponer políticas ambientales

Metodologías para proyectos de datos

- KDD
- CRISP-DM

Docente: Soledad Espezúa Llerena

Knowledge data discovery (KDD)

- También se conoce como: extracción de conocimiento, descubrimiento de información, recolección de información, arqueología de datos, procesamiento de patrones de datos.
- Integración diversas disciplinas: bases de datos, ML, reconocimiento de patrones, estadística, AI.
- Se apoya en: conocimiento de expertos, visualización, descubrimientos científicos.

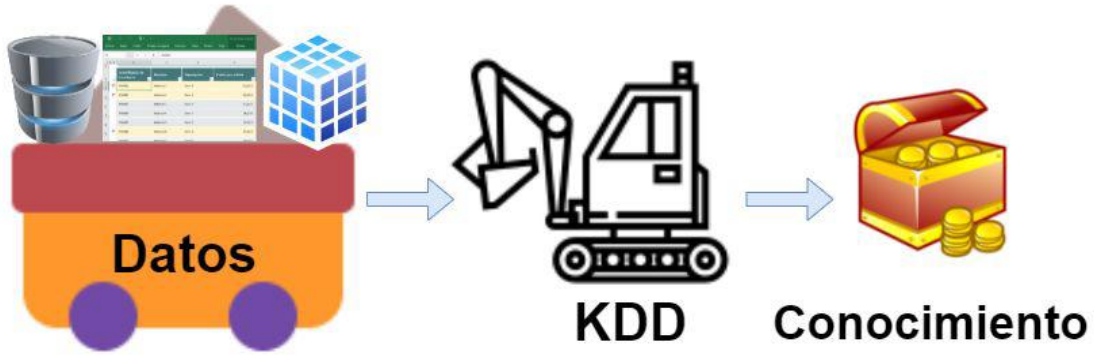
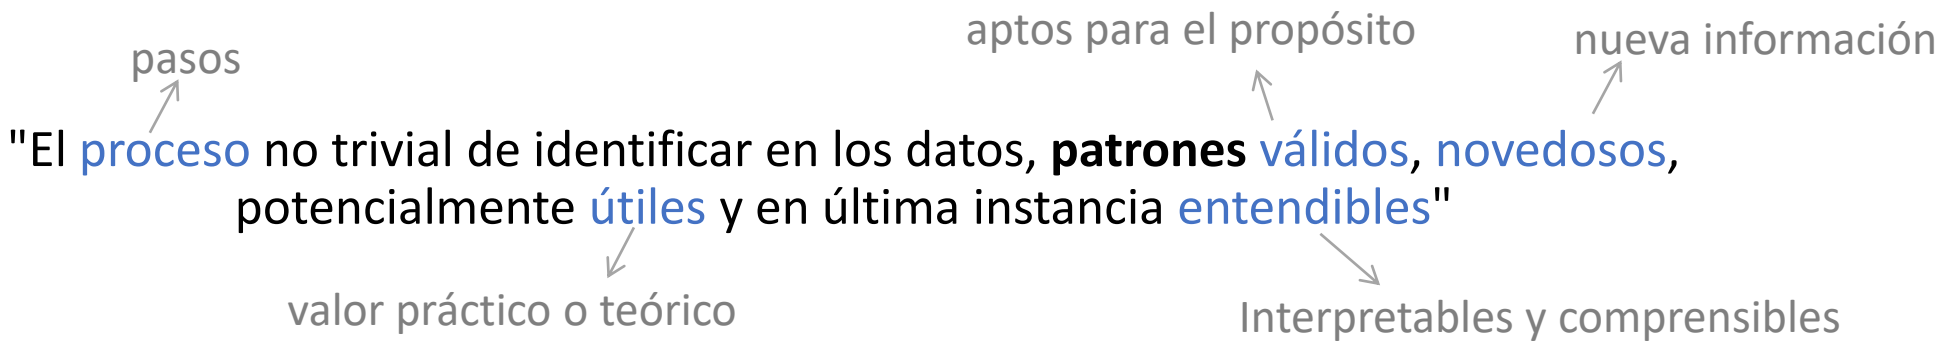


Imagen tomada de:
https://www.campusmvp.es/recursos/post/el-proceso-de-extraccion-de-conocimiento-a-partir-de-bases-de-datos.aspx

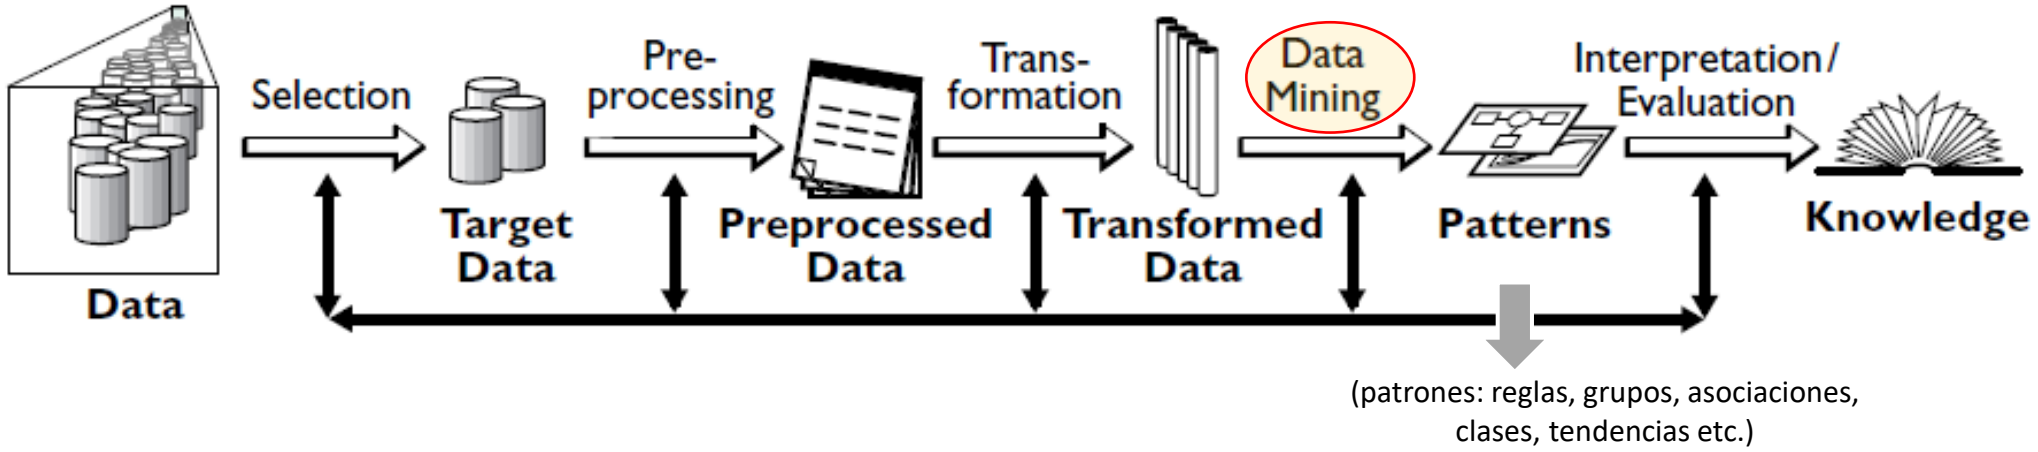
Knowledge data discovery (KDD)



- Un **patrón** es una estructura, regularidad o relación identificada en los datos que aporta información útil. Puede aparecer como una tendencia, una agrupación, una asociación entre variables o una anomalía.

Adaptado de: U. Fayyad, G. Piatetsky-Shapiro, P. Smyth. (1996). *Data Mining to Knowledge Discovery: An Overview*. Advances in Knowledge Discovery and Data Mining,

Proceso KDD



Data Mining no abarca todo el proceso KDD; es la etapa en la que se aplican algoritmos para descubrir patrones (reglas, grupos, clases o tendencias en los datos).

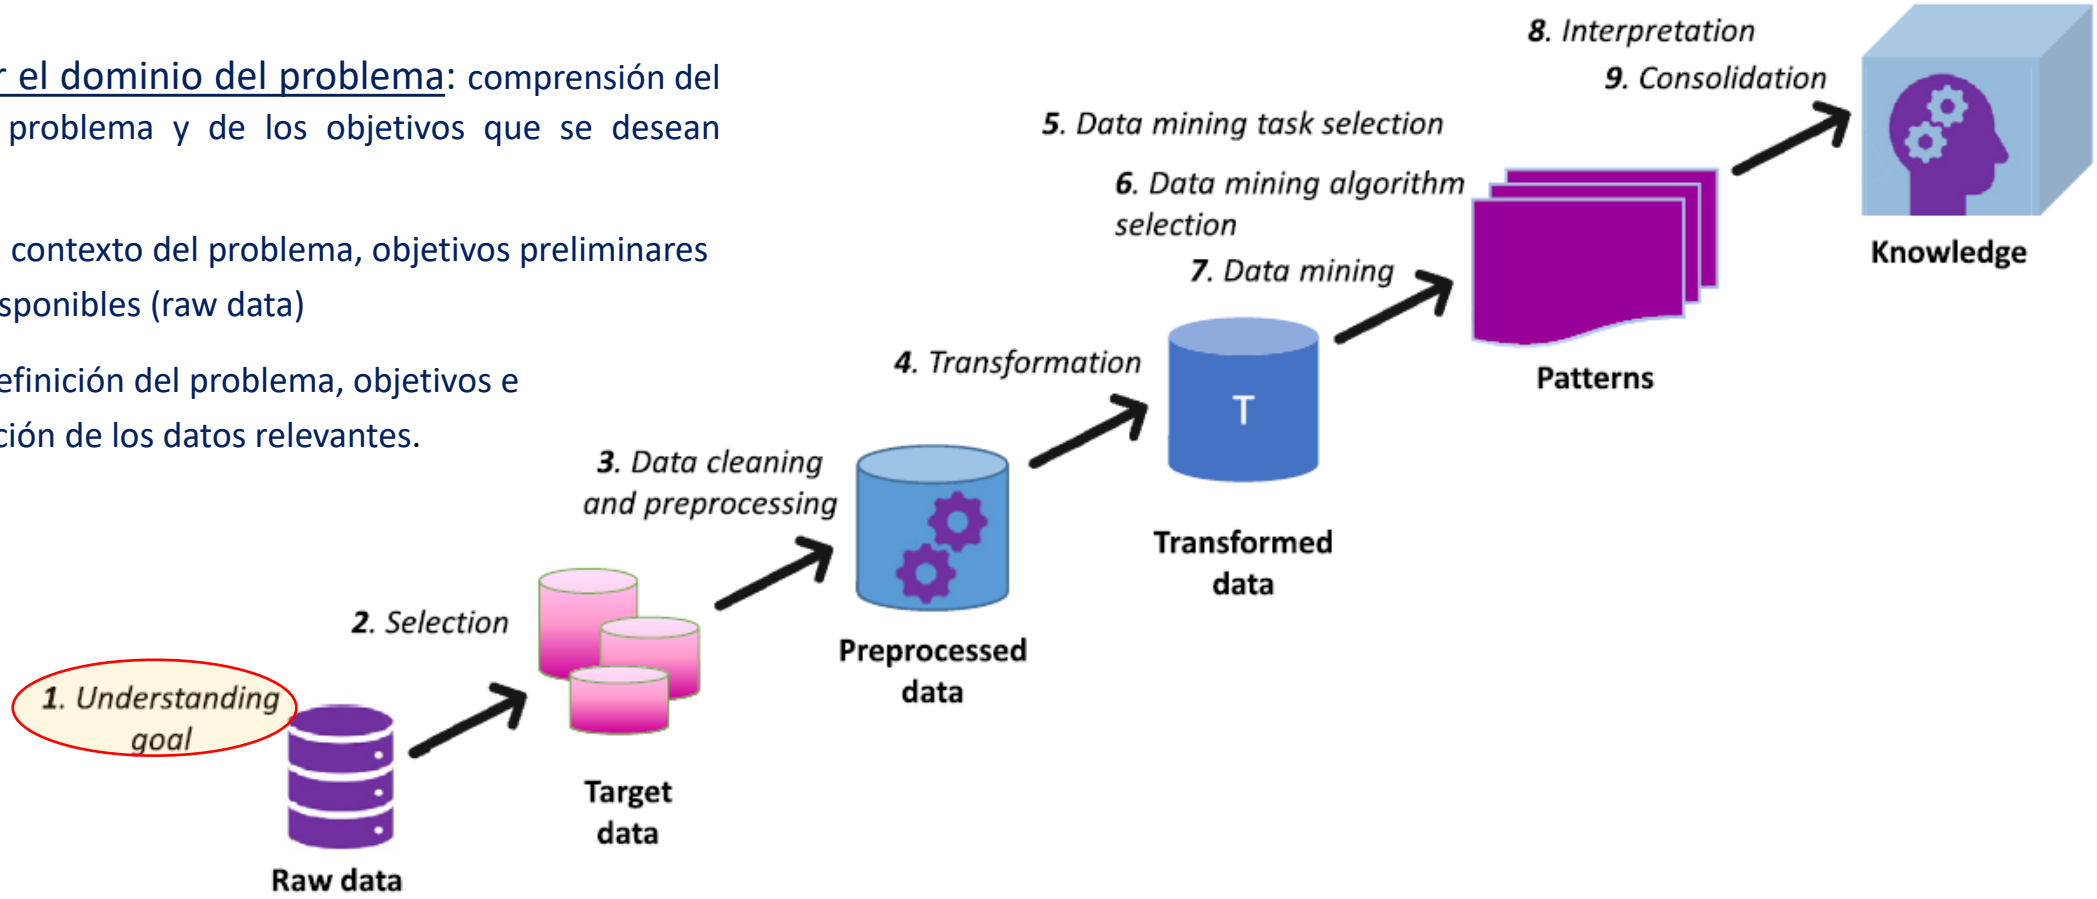
Adaptado de: U. Fayyad, G. Piatetsky-Shapiro, P. Smyth. (1996). *Data Mining to Knowledge Discovery: An Overview*. Advances in Knowledge Discovery and Data Mining,

Fases del proceso KDD

1. Entender el dominio del problema: comprensión del contexto, problema y de los objetivos que se desean alcanzar.

   entrada: contexto del problema, objetivos preliminares y datos disponibles (raw data)

   salida: definición del problema, objetivos e identificación de los datos relevantes.

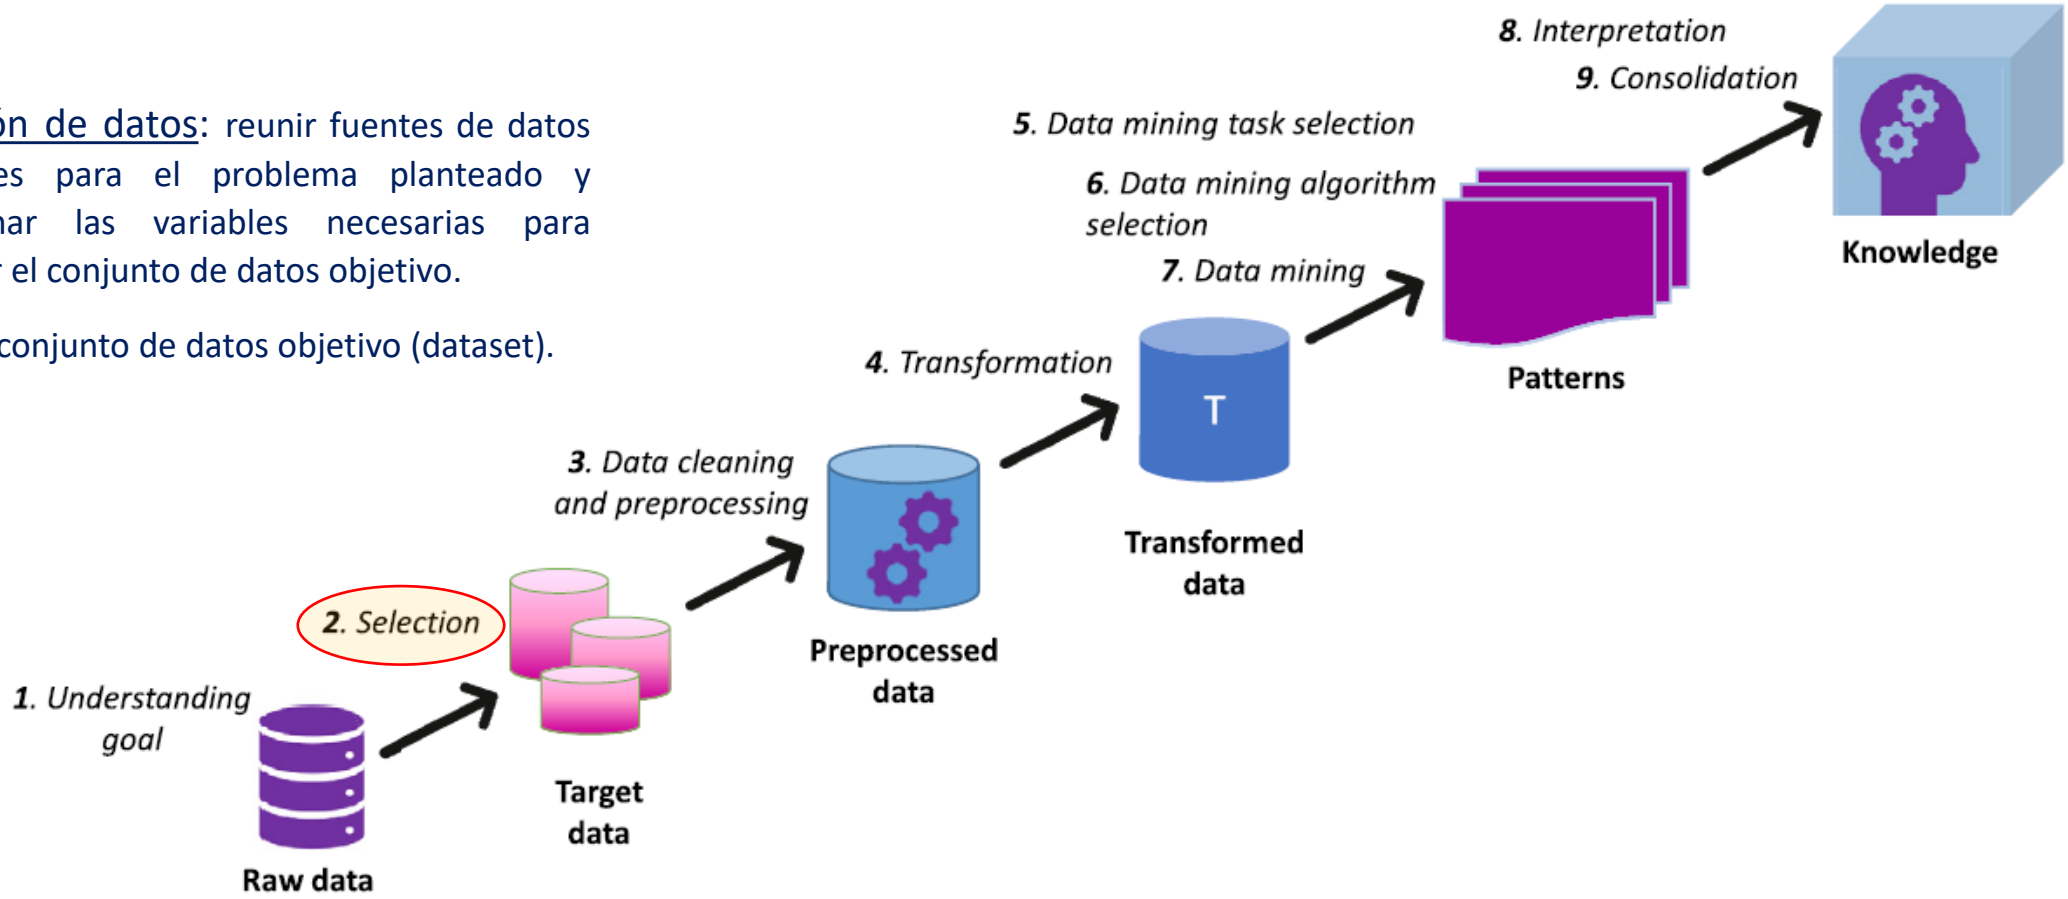


Adaptado de: Butka, P., Bednár, P., y Ivančáková, J. (2020). *Methodologies for Knowledge Discovery Processes in Context of AstroGeoInformatics*. In Knowledge Discovery in Big Data from Astronomy and Earth Observation (pp. 1-20). Elsevier.

Fases del proceso KDD

2. Selección de datos: reunir fuentes de datos relevantes para el problema planteado y seleccionar las variables necesarias para construir el conjunto de datos objetivo.

   salida: conjunto de datos objetivo (dataset).

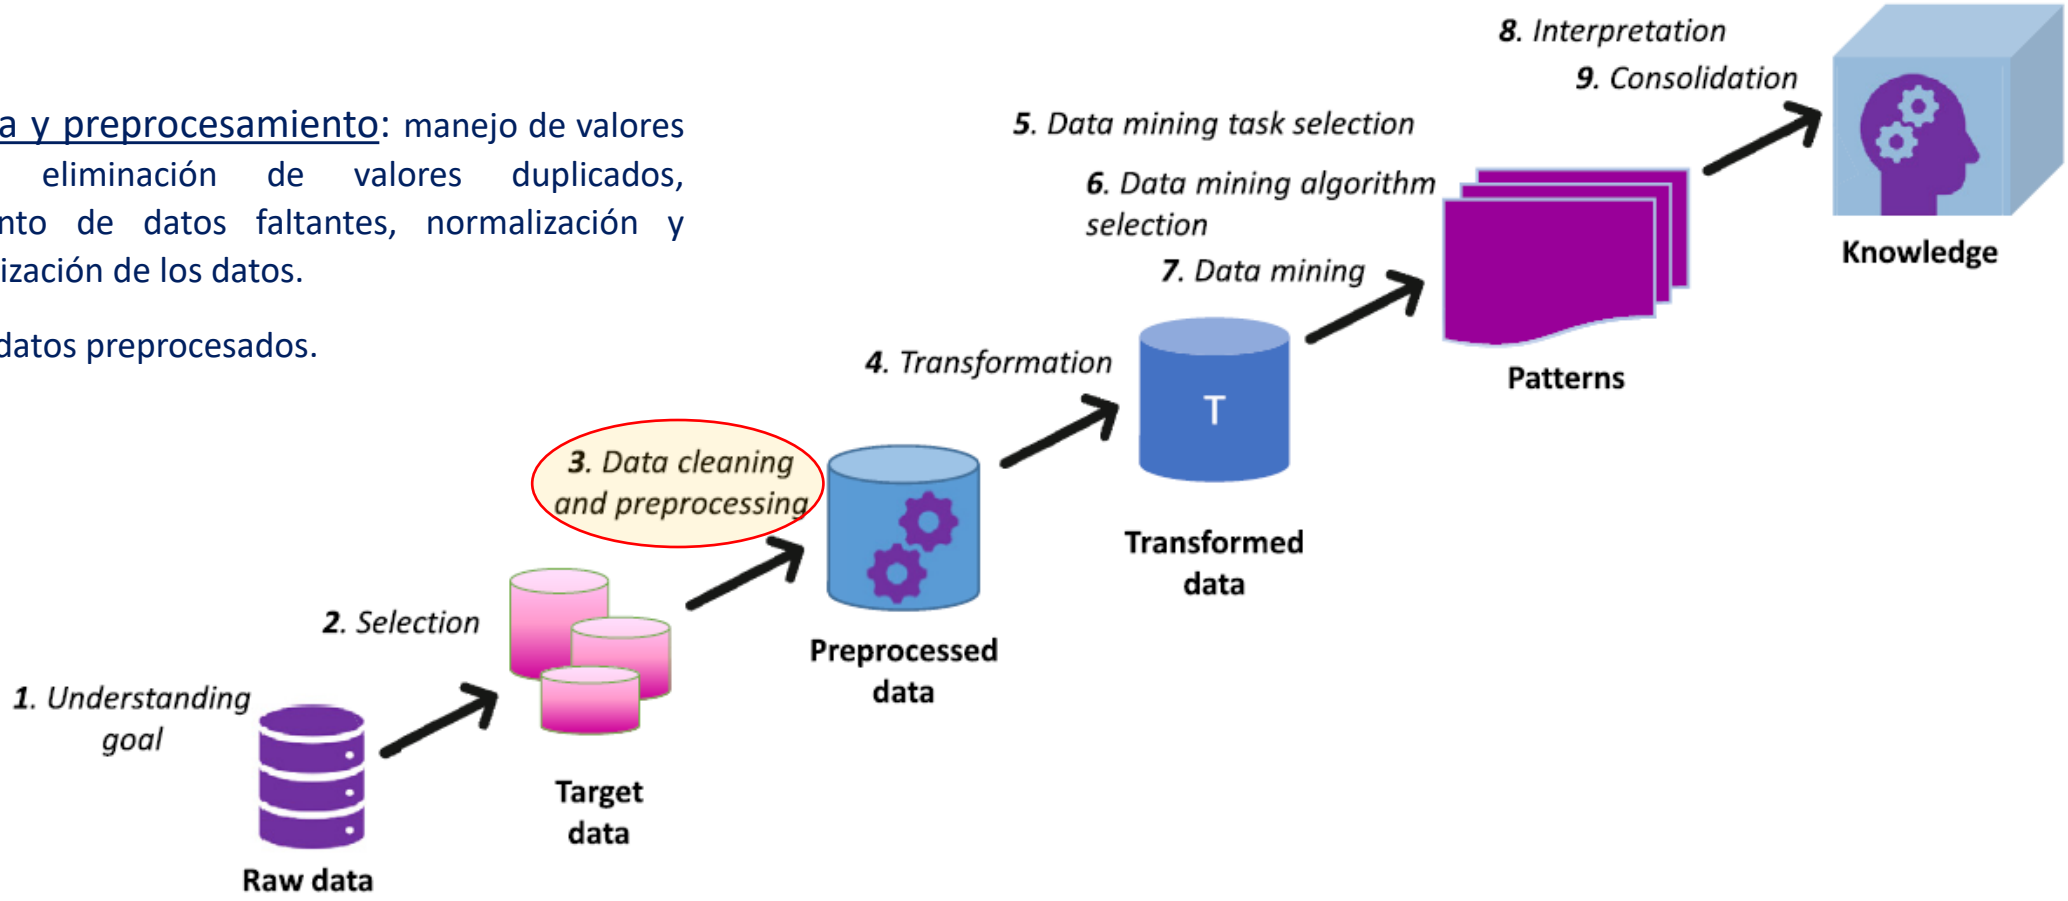


Adaptado de: Butka, P., Bednár, P., y Ivančáková, J. (2020). *Methodologies for Knowledge Discovery Processes in Context of AstroGeoInformatics*. In Knowledge Discovery in Big Data from Astronomy and Earth Observation (pp. 1-20). Elsevier.

Fases del proceso KDD

3. Limpieza y preprocesamiento: manejo de valores atípicos, eliminación de valores duplicados, tratamiento de datos faltantes, normalización y estandarización de los datos.

   salida: datos preprocesados.

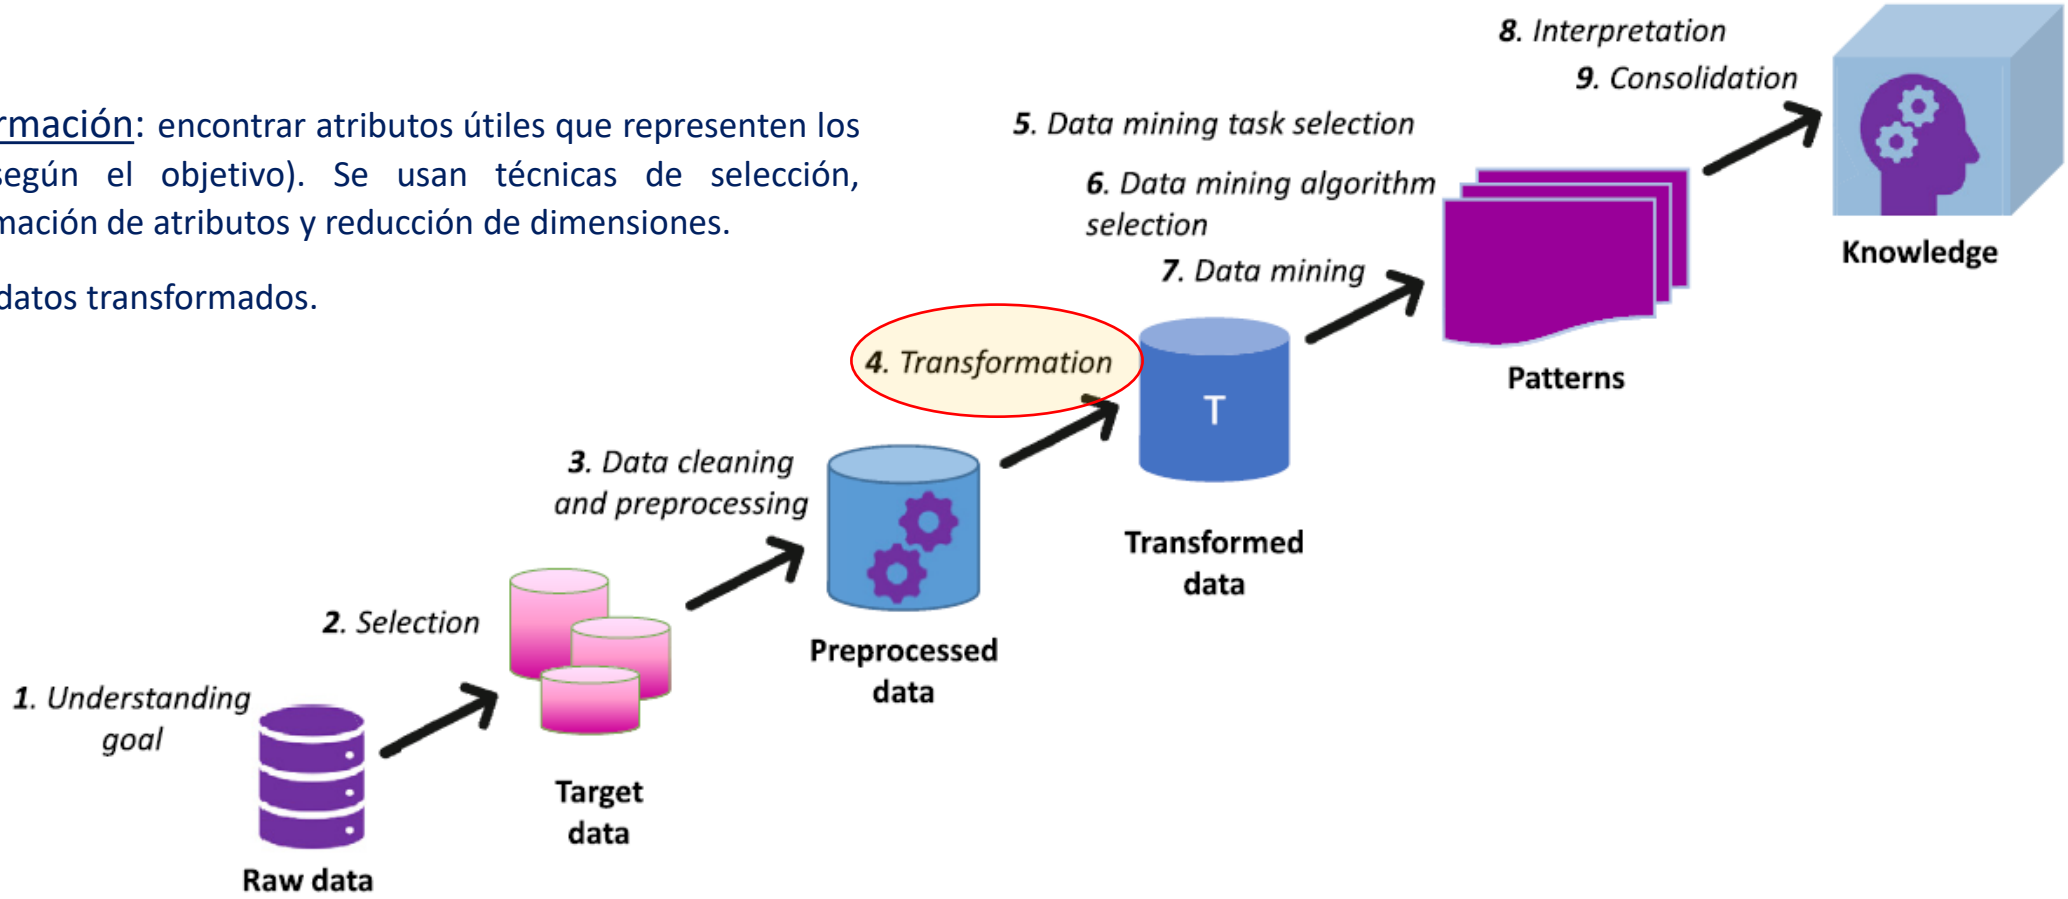


Adaptado de: Butka, P., Bednár, P., y Ivančáková, J. (2020). *Methodologies for Knowledge Discovery Processes in Context of AstroGeoInformatics*. In Knowledge Discovery in Big Data from Astronomy and Earth Observation (pp. 1-20). Elsevier.

Fases del proceso KDD

4. Transformación: encontrar atributos útiles que representen los datos (según el objetivo). Se usan técnicas de selección, transformación de atributos y reducción de dimensiones.

   salida: datos transformados.



Adaptado de: Butka, P., Bednár, P., y Ivančáková, J. (2020). *Methodologies for Knowledge Discovery Processes in Context of AstroGeoInformatics*. In Knowledge Discovery in Big Data from Astronomy and Earth Observation (pp. 1-20). Elsevier.

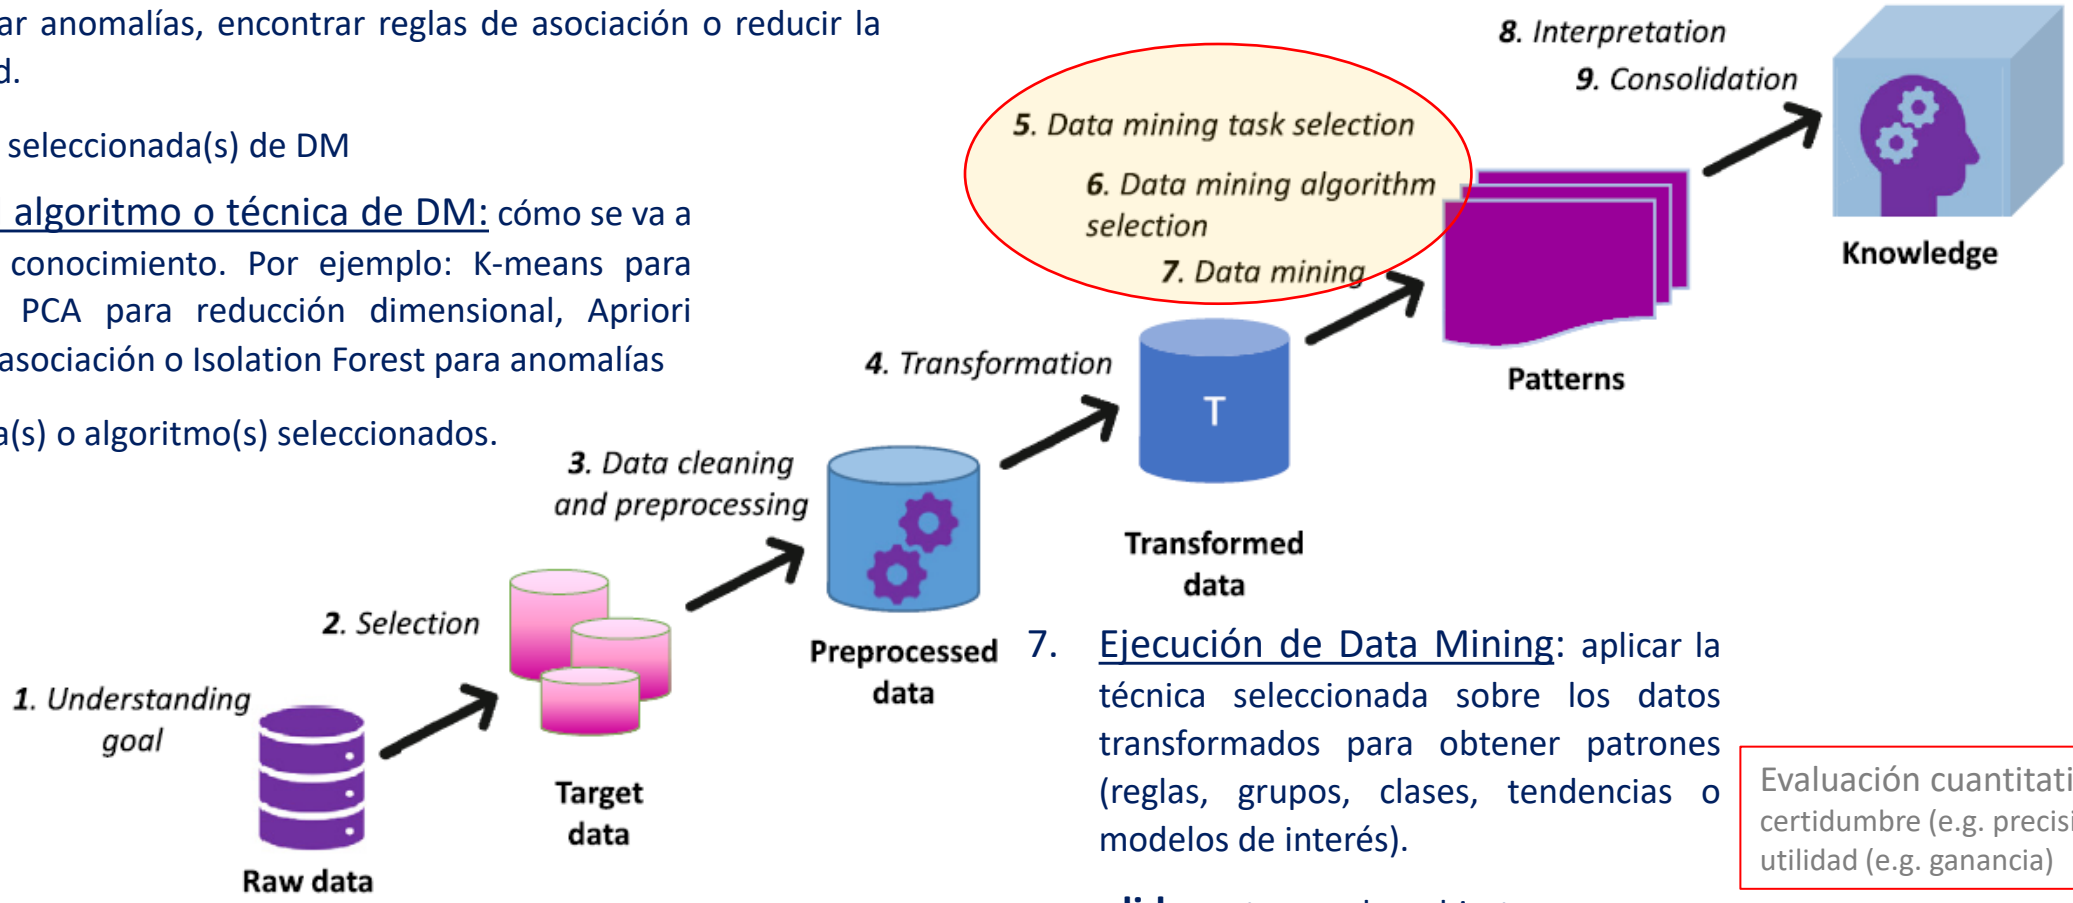
Fases del proceso KDD

5. Selección de tarea: qué se desea descubrir. Por ejemplo: segmentar clientes, detectar anomalías, encontrar reglas de asociación o reducir la dimensionalidad.

   salida: tarea(s) seleccionada(s) de DM

6. Selección del algoritmo o técnica de DM: cómo se va a descubrir ese conocimiento. Por ejemplo: K-means para segmentación, PCA para reducción dimensional, Apriori para reglas de asociación o Isolation Forest para anomalías

   salida: técnica(s) o algoritmo(s) seleccionados.



7. Ejecución de Data Mining: aplicar la técnica seleccionada sobre los datos transformados para obtener patrones (reglas, grupos, clases, tendencias o modelos de interés).

   salida: patrones descubiertos.

Evaluación cuantitativa: certidumbre (e.g. precisión), utilidad (e.g. ganancia)

Adaptado de: Butka, P., Bednár, P., y Ivančáková, J. (2020). *Methodologies for Knowledge Discovery Processes in Context of AstroGeoInformatics*. In Knowledge Discovery in Big Data from Astronomy and Earth Observation (pp. 1-20). Elsevier.

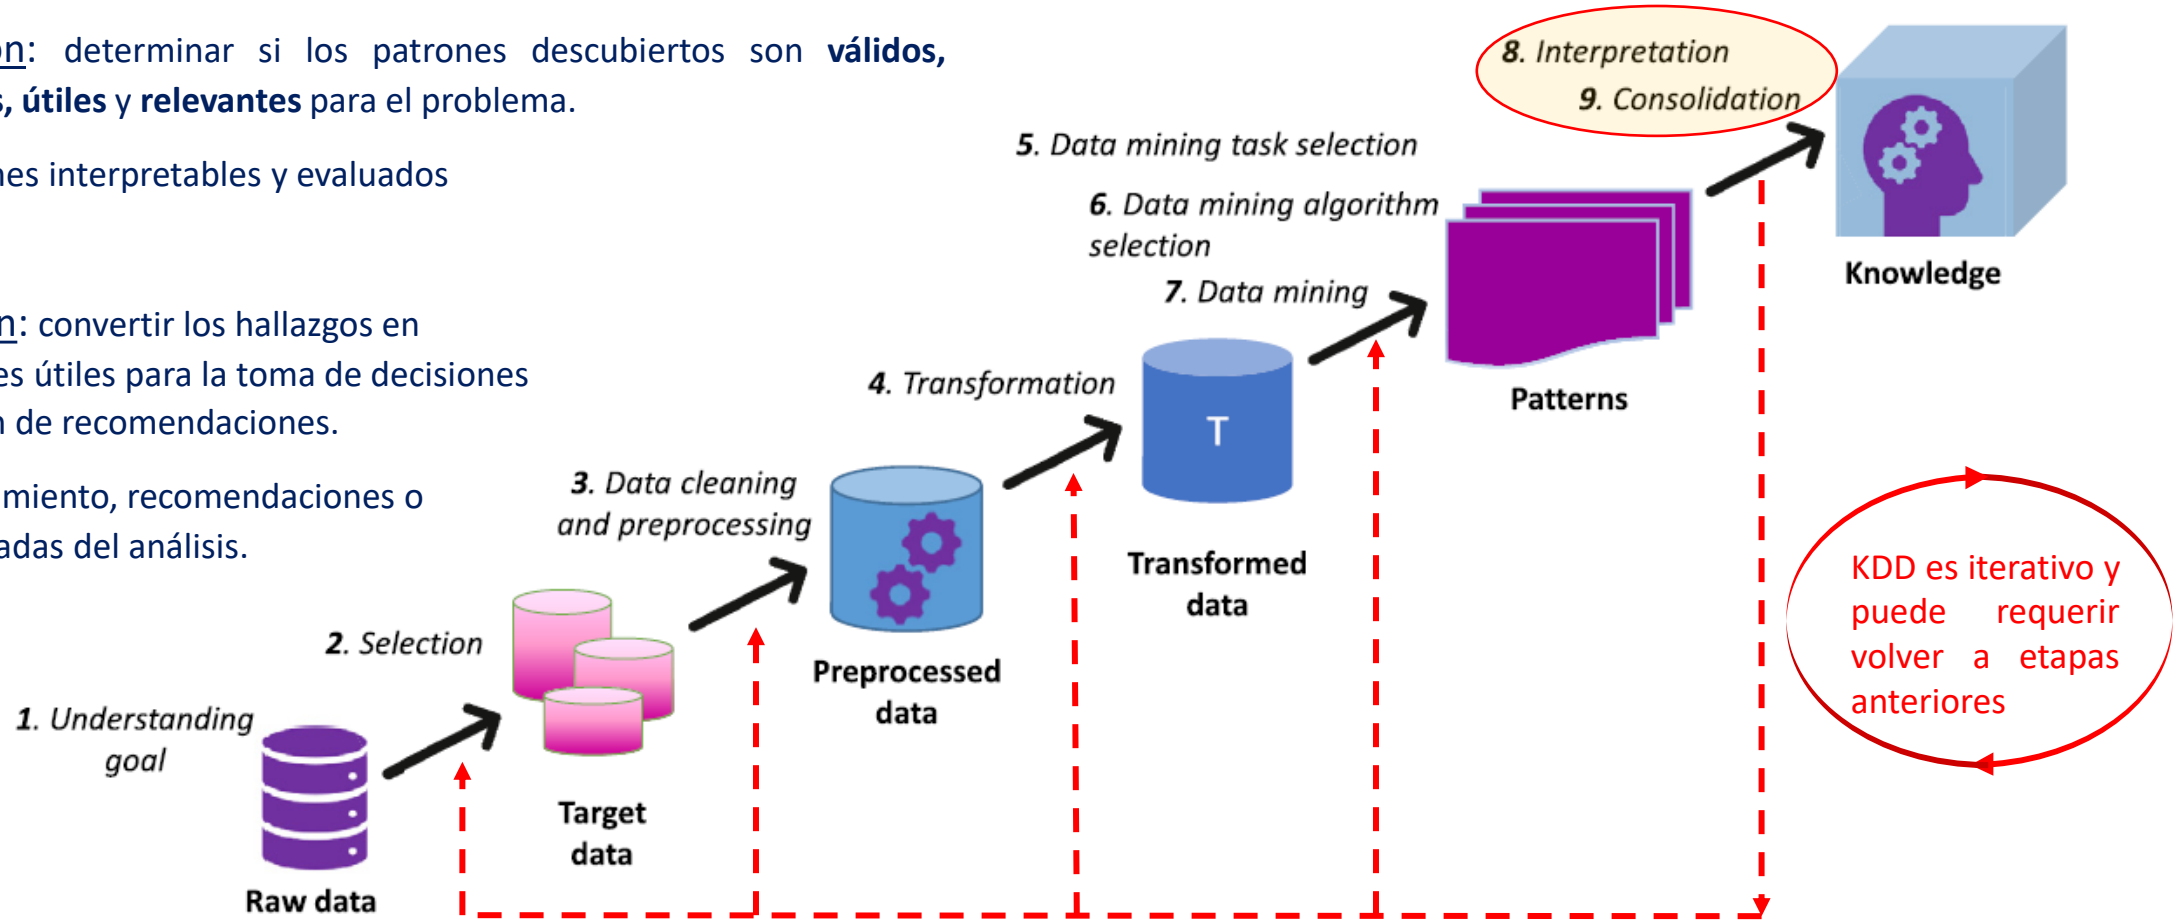
Fases del proceso KDD

8. Interpretación: determinar si los patrones descubiertos son **válidos, comprensibles, útiles** y **relevantes** para el problema.

   salida: patrones interpretables y evaluados

9. Consolidación: convertir los hallazgos en interpretaciones útiles para la toma de decisiones o la generación de recomendaciones.

   salida: conocimiento, recomendaciones o acciones derivadas del análisis.



Butka, P., Bednár, P., y Ivančáková, J. (2020). *Methodologies for Knowledge Discovery Processes in Context of AstroGeoInformatics*. In Knowledge Discovery in Big Data from Astronomy and Earth Observation (pp. 1-20). Elsevier.

UNIVERSIDAD DEL PACÍFICO

¡Gracias por su atención!