UNIVERSIDAD DEL PACÍFICO



Sesión 2
Fundamentos de Minería de Datos

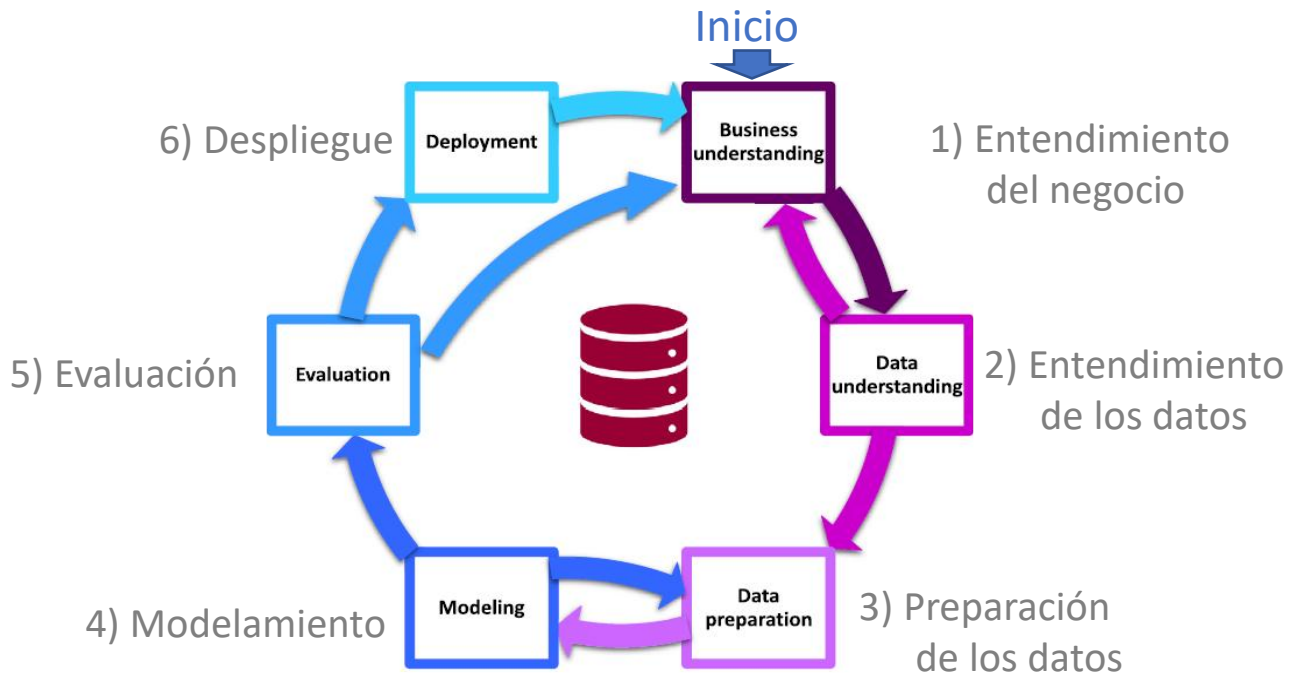
Docente: Soledad Espezua Llerena

s.espezual@up.edu.pe

CRISP-DM

CRoss Industry Standard Process for Data Mining

- **Metodología general** para desarrollar proyectos de DM en la industria.
- Desarrollado por un consorcio de empresas, con el objetivo de proponer un marco común, repetible y práctico para proyectos de DM.



Adaptado de: Butka, P., Bednár, P., y Ivančáková, J. (2020). *Methodologies for Knowledge Discovery Processes in Context of AstroGeoInformatics*. In Knowledge Discovery in Big Data from Astronomy and Earth Observation (pp. 1-20). Elsevier.

1. Entendimiento del Negocio

Realizar un **análisis de requisitos** y **datos** disponibles:

- Determinar los objetivos del negocio:
  - Antecedentes, objetivos estratégicos de impacto y criterios de éxito.
- Explorar aspectos técnicos:
  - cómo obtener datos
  - formatos de datos
  - seguridad
  - anonimización de datos
  - herramientas de software
  - despliegue técnico.

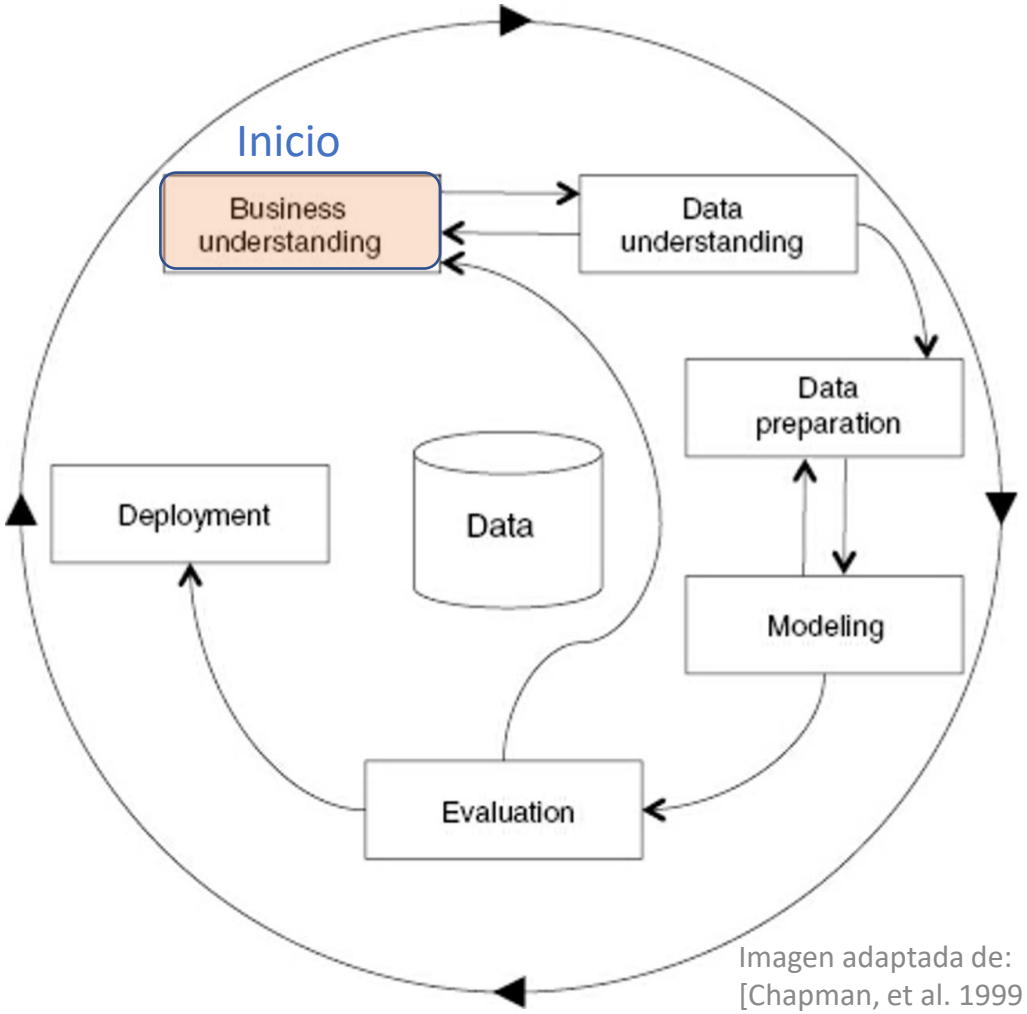


Imagen adaptada de:
[Chapman, et al. 1999]

Adaptado de: Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., Wirth, R., (2000). Crisp-DM 1.0 step-by-step data mining guide. Technical report. The CRISP-DM Consortium

2. Entendimiento de los Datos

Identificar datos **interesantes** de analizar:

- Recopilar datos iniciales: crear las primeras versiones del conjunto de datos.
- Describir atributos, resumir datos iniciales, extraer atributos básicos.
- Explorar datos: visualizaciones, correlaciones, análisis de estadísticas simples.
- Verificar calidad de los datos: analizar valores faltantes, anomalías u otros problemas.

Nota: Invertir tiempo en entender el problema. Si es necesario, podemos volver al paso anterior (entendimiento del negocio).

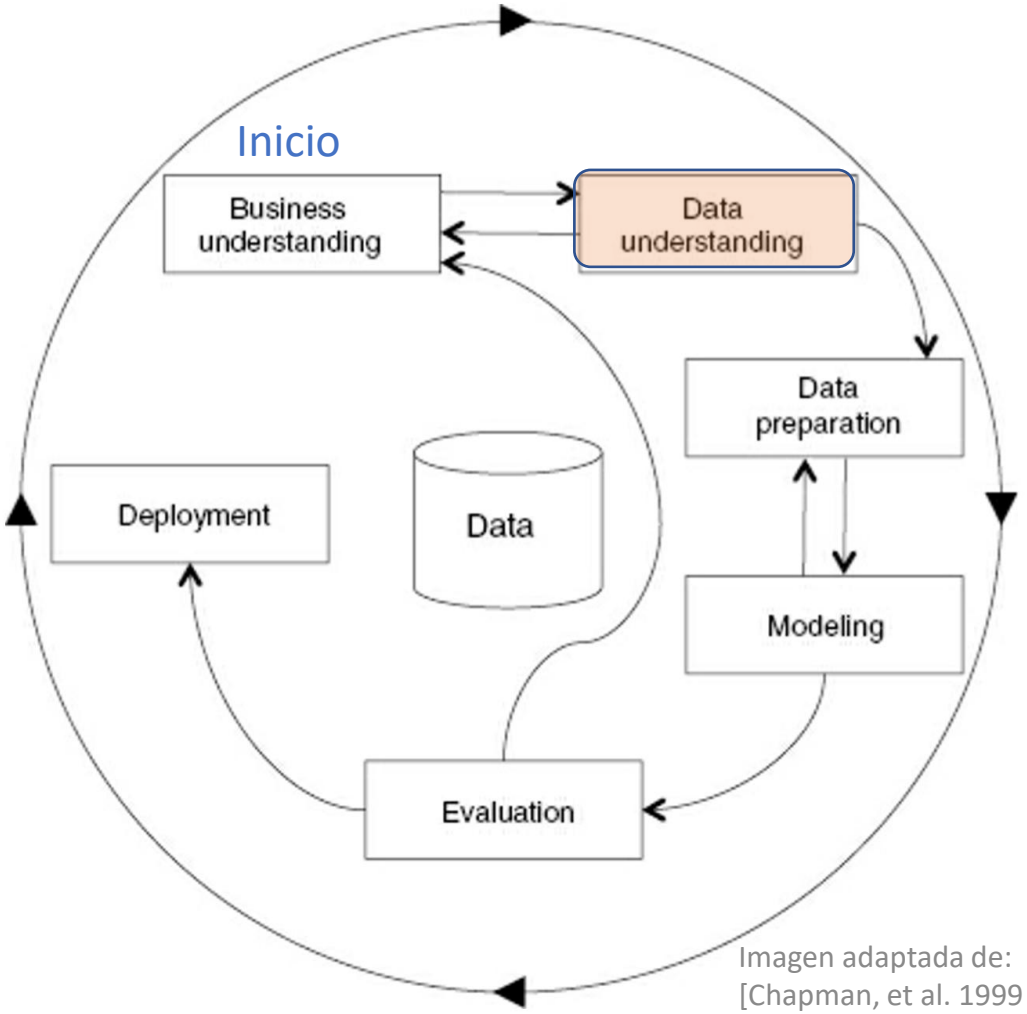


Imagen adaptada de:
[Chapman, et al. 1999]

Adaptado de: Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., Wirth, R., (2000). Crisp-DM 1.0 step-by-step data mining guide. Technical report. The CRISP-DM Consortium

3. Preparación de Datos

Convertir los datos disponibles en un conjunto de **datos adecuado** para el modelamiento:

- Seleccionar las fuentes, tablas, registros y atributos relevantes para el objetivo del proyecto.
- Integrar información proveniente de distintas fuentes o tablas.
- Limpiar datos: valores faltantes, errores, inconsistencias, duplicados y valores atípicos.
- Transformar datos: crear nuevos atributos, normalizar y reducir dimensionalidad.
- Organizar los datos en la estructura requerida por el algoritmo o técnica a utilizar.

Nota: Si ya existe una base de datos, esta integración puede ser relativamente fácil.

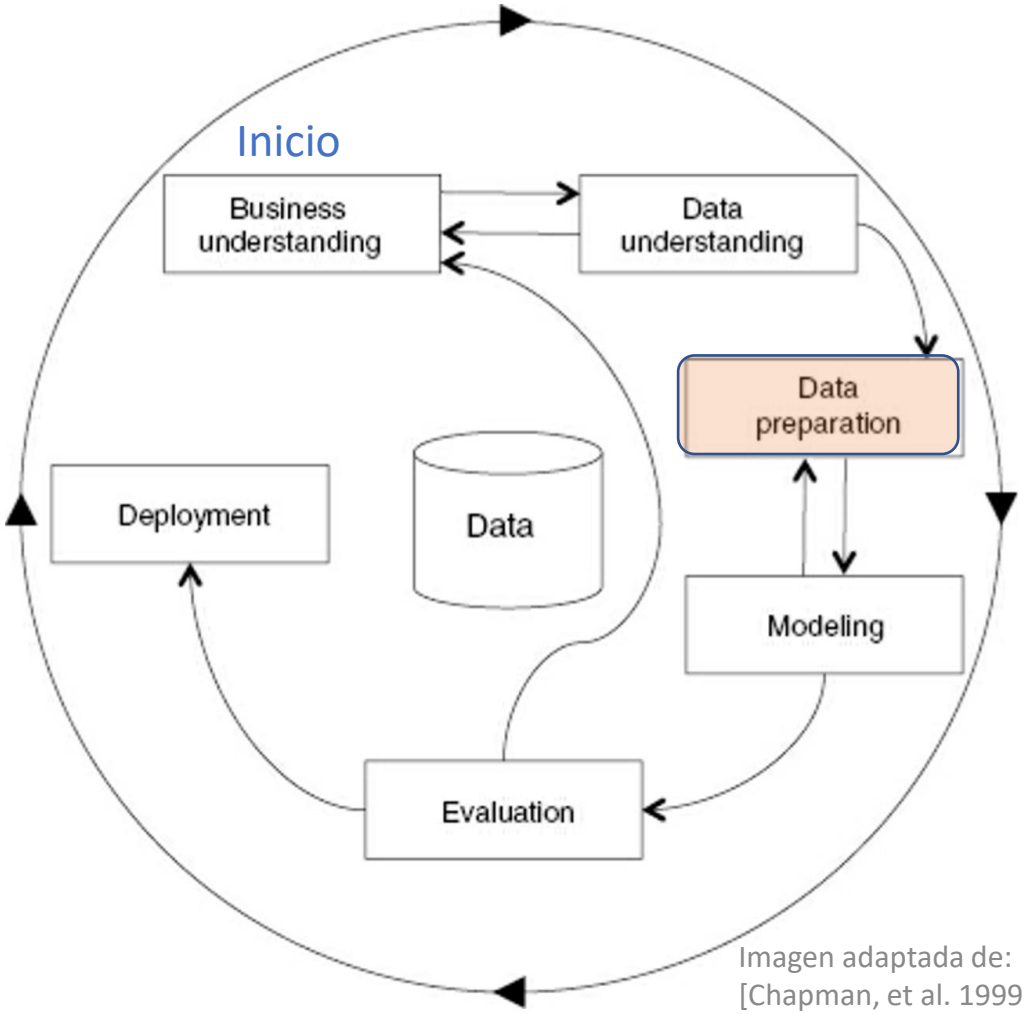


Imagen adaptada de:
[Chapman, et al. 1999]

Adaptado de: Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., Wirth, R., (2000). Crisp-DM 1.0 step-by-step data mining guide. Technical report. The CRISP-DM Consortium

4. Modelamiento

Aplicar técnicas de **minería de datos y/o *machine learning*** sobre los datos preparados para descubrir patrones (relaciones, grupos, reglas) o modelos predictivos:

- Seleccionar la técnica: elegir el método según el tipo de problema: clasificación, clustering, reglas de asociación, predicción, etc.
- Dividir el dataset: separar los datos para entrenamiento, validación y test, cuando corresponda.
- Construir modelos o patrones: ejecutar los algoritmos seleccionados sobre los datos preparados.
- Evaluar los resultados iniciales: analizar el desempeño, afinar parámetros y comparar alternativas.

Nota: Un algoritmo puede generar un modelo o descubrir patrones útiles en los datos. En problemas de *machine learning*, el modelo aprende a partir de un conjunto de datos para realizar tareas como clasificar, predecir o agrupar.

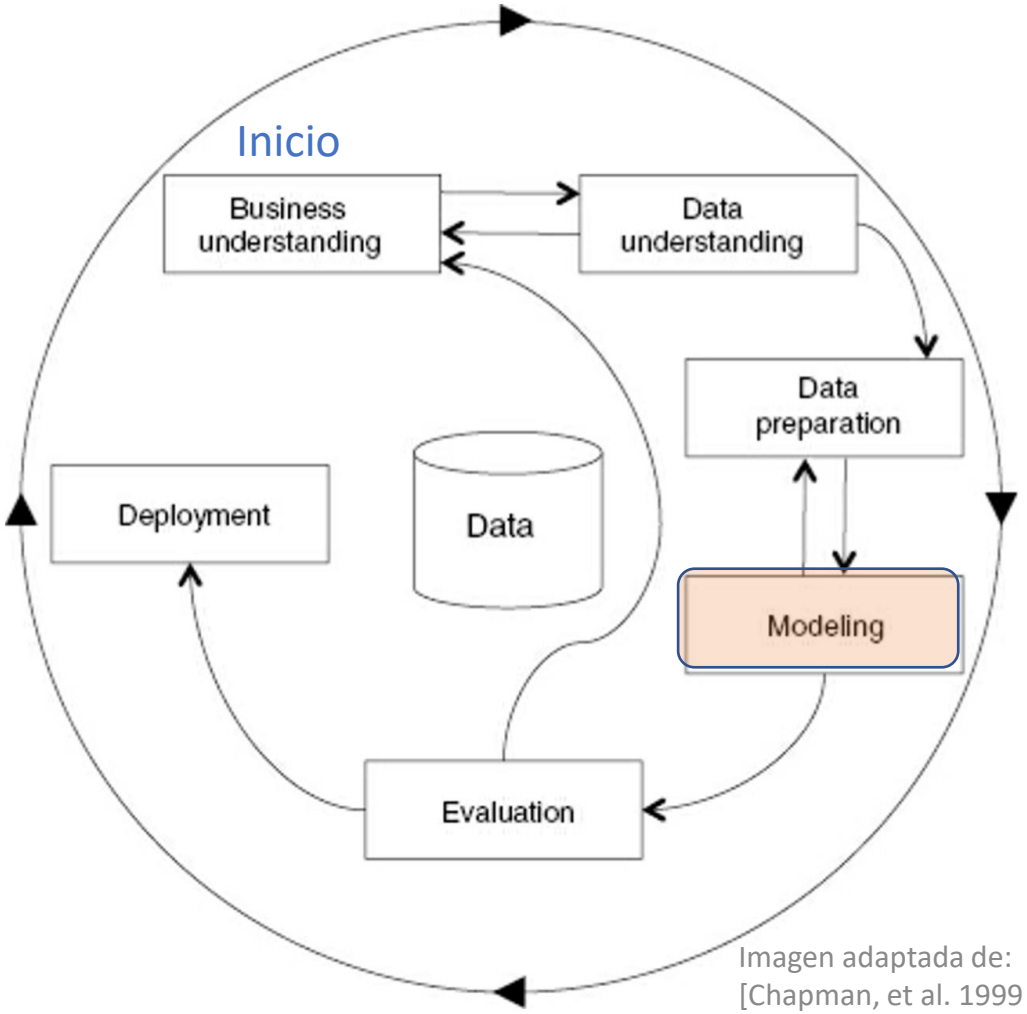


Imagen adaptada de:
[Chapman, et al. 1999]

Adaptado de: Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., Wirth, R., (2000). Crisp-DM 1.0 step-by-step data mining guide. Technical report. The CRISP-DM Consortium

CRISP-DM: Preparación de datos y Modelamiento

Al probar los **primeros modelos**, muchas veces se detectan **problemas** en los datos o en las variables utilizadas. Por ello, es común **volver a la preparación** de datos para corregir, transformar o crear nuevas variables y luego entrenar nuevamente.

Ciclo de retroalimentación:

- Se prepara el conjunto de datos.
- Se prueban algoritmos y configuraciones iniciales.
- Se evalúa el desempeño del modelo.
- Si los resultados no son adecuados, se revisan los datos.
- Se ajustan variables, transformaciones o filtros.
- Se vuelve a modelar y comparar resultados.

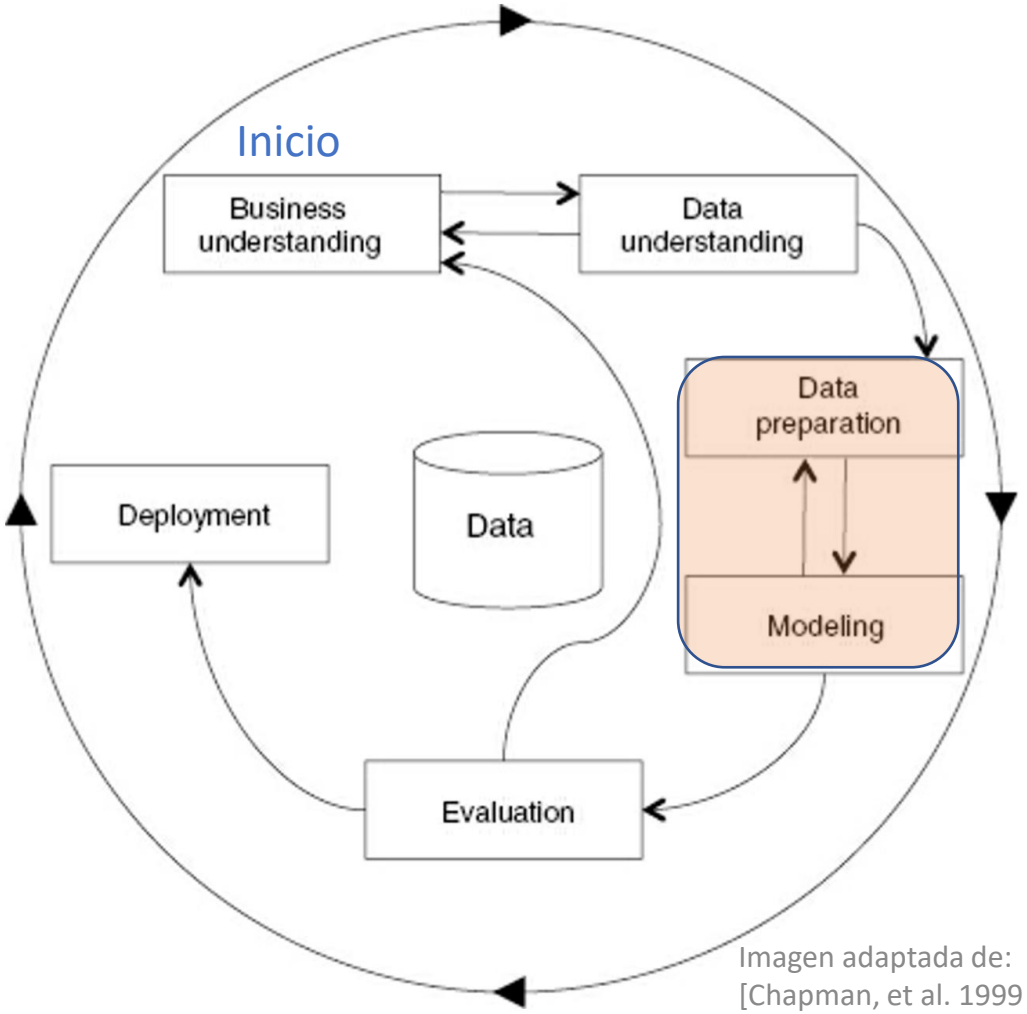


Imagen adaptada de:
[Chapman, et al. 1999]

Adaptado de: Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., Wirth, R., (2000). Crisp-DM 1.0 step-by-step data mining guide. Technical report. The CRISP-DM Consortium

5. Evaluación

La evaluación permite decidir si los **resultados** obtenidos son técnicamente **válidos y útiles** para el problema planteado. Si no lo son, se ajusta el proceso y se vuelve a fases anteriores:

- Evaluar resultados: analizar métricas, calidad y utilidad de los modelos o patrones encontrados.
- Revisar el proceso: verificar si el modelo responde al problema inicial y si los datos usados fueron adecuados.
- Decidir el siguiente paso: aprobar el modelo, ajustar el proceso o regresar a una fase anterior.
- Preparar recomendaciones: identificar ventajas, limitaciones y posibles acciones antes del despliegue.

Nota: Si el modelo no responde bien al objetivo del proyecto se regresa a etapas anteriores del ciclo CRISP-DM

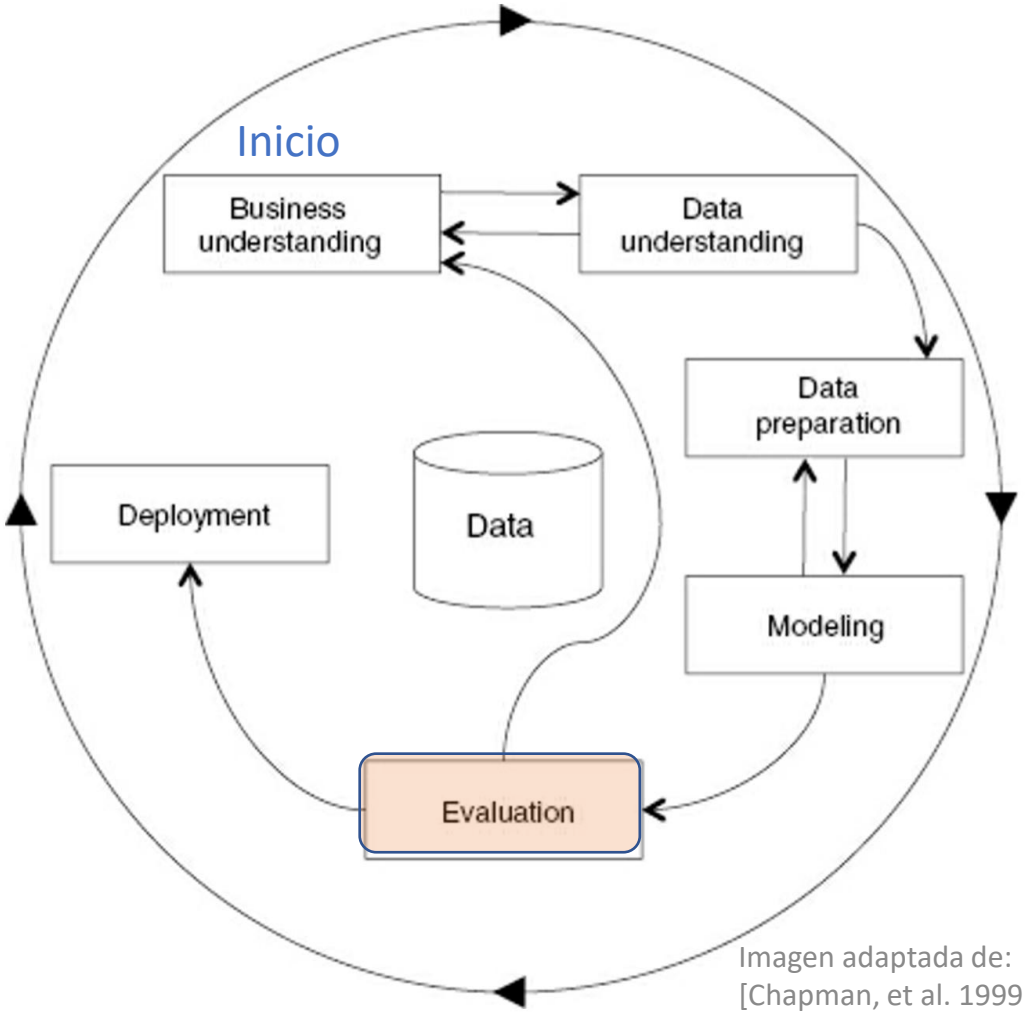


Imagen adaptada de:
[Chapman, et al. 1999]

Adaptado de: Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., Wirth, R., (2000). Crisp-DM 1.0 step-by-step data mining guide. Technical report. The CRISP-DM Consortium

6. Despliegue

Implementar los resultados del proyecto en un contexto real de uso. Esto puede implicar **integrar** un modelo, reporte, tablero o conjunto de recomendaciones dentro de los procesos de la organización:

- Planificar la implementación: definir cómo se usará el modelo o resultado obtenido.
- Integrar la solución: incorporar el modelo, reporte o análisis en los procesos del negocio.
- Monitorear resultados: revisar periódicamente el desempeño, la utilidad y posibles cambios en los datos.
- Documentar el proyecto: preparar el informe final, lecciones aprendidas y recomendaciones.

Nota: El despliegue no siempre significa poner un modelo en producción. También puede ser entregar un reporte, una visualización, una regla de decisión o una recomendación basada en los patrones encontrados.

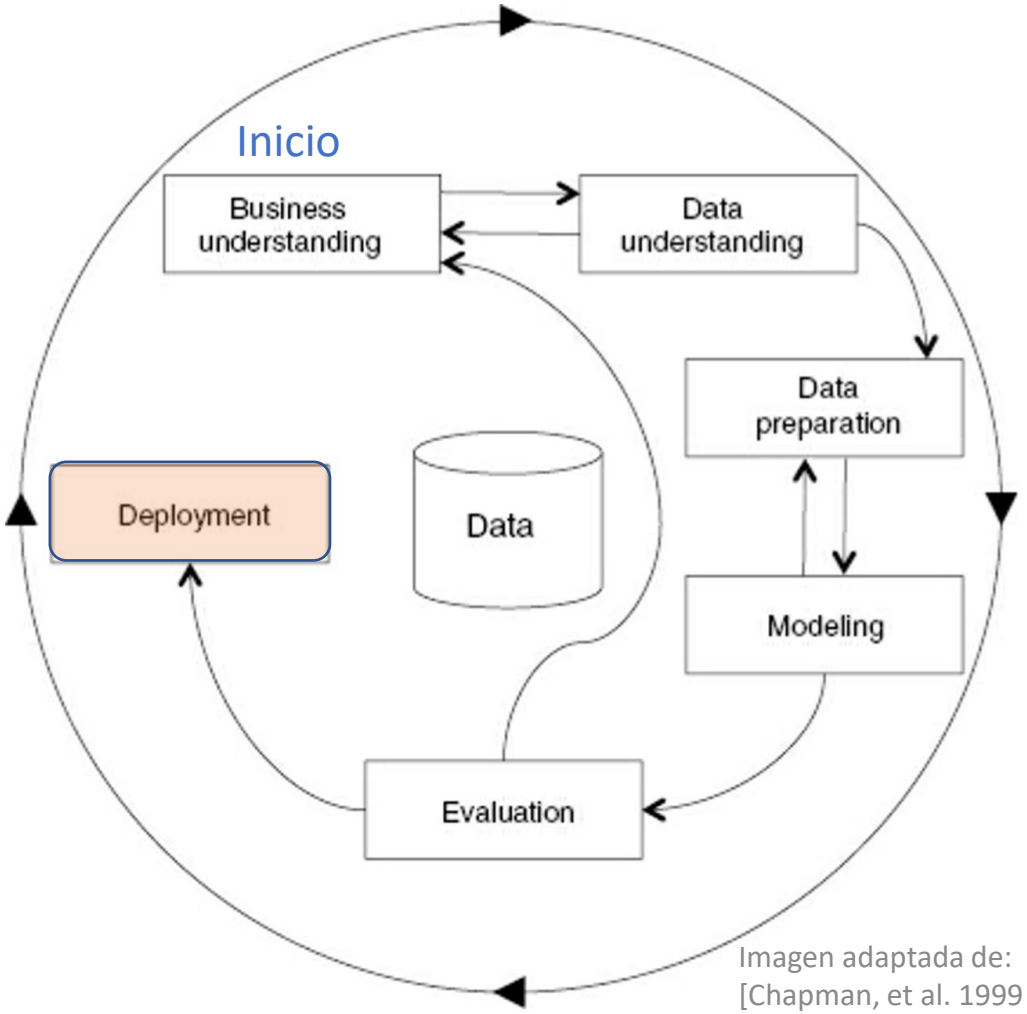


Imagen adaptada de:
[Chapman, et al. 1999]

Adaptado de: Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., Wirth, R., (2000). Crisp-DM 1.0 step-by-step data mining guide. Technical report. The CRISP-DM Consortium

Iteración y reinicio

CRISP-DM no es lineal. Los objetivos, datos o resultados pueden cambiar durante el proyecto, por lo que puede ser necesario volver a fases anteriores.

¿Cuándo se reinicia o se itera?

- Cuando cambian las necesidades del negocio.
- Cuando los datos disponibles no son suficientes o adecuados.
- Cuando el modelo no cumple los objetivos esperados.
- Cuando aparecen nuevos hallazgos o restricciones.

Acciones:

- Revisar objetivos, datos y contexto. Decidir si se continúa, ajusta o reinicia el proceso. Retornar a fases anteriores cuando sea necesario. Actualizar el plan de trabajo según los resultados.

Nota: La iteración permite mejorar el proyecto y adaptarlo a cambios del problema real.

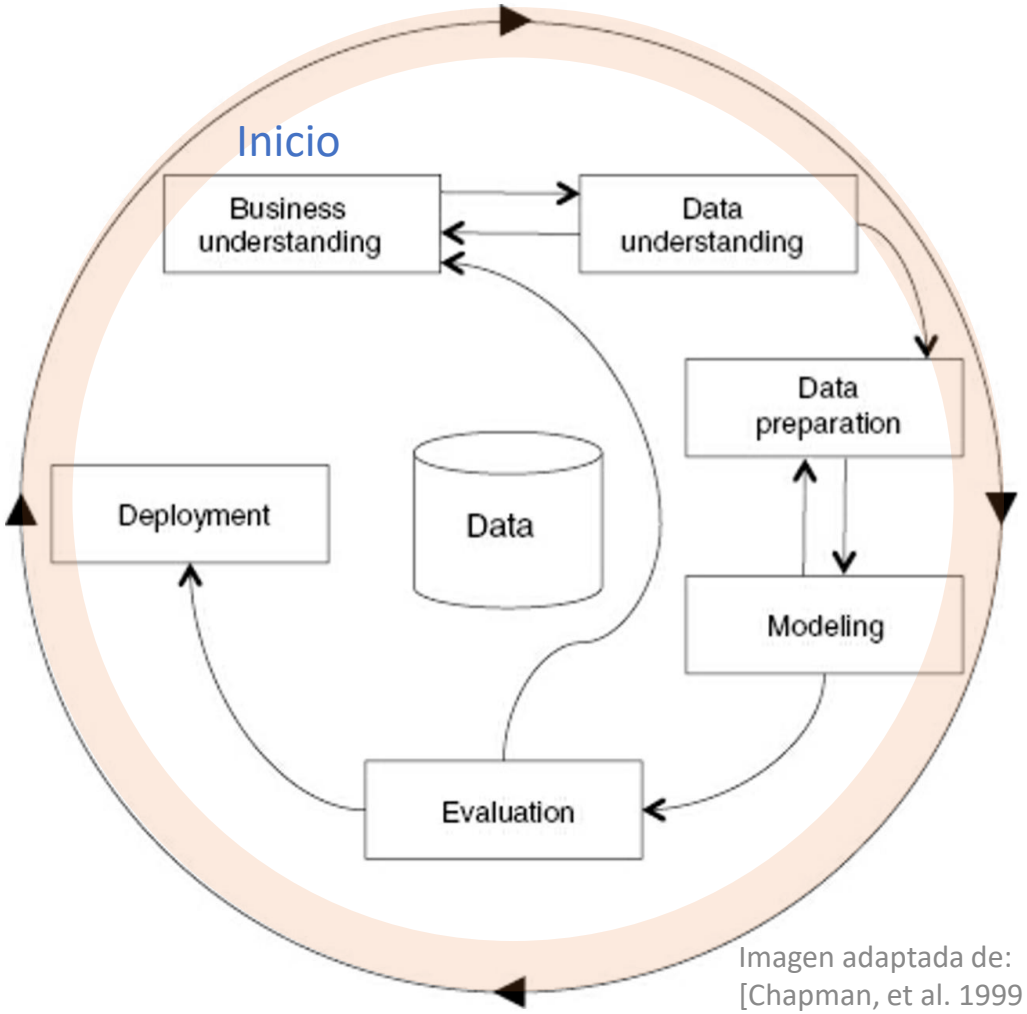


Imagen adaptada de:
[Chapman, et al. 1999]

Adaptado de: Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., Wirth, R., (2000). Crisp-DM 1.0 step-by-step data mining guide. Technical report. The CRISP-DM Consortium

Otras metodologías

▪ **SEMMA**: enfoque práctico para explorar, transformar, modelar y evaluar datos.	SAS Institute Inc. *Introduction to SAS Enterprise Miner Software: Data Mining Overview*. SAS Support Documentation.
▪ **TDSP**: marco para proyectos de ciencia de datos en equipos.	Microsoft. *What is the Data Science Lifecycle?* Microsoft Learn.
▪ **OSEMN**: flujo simple: obtener, limpiar, explorar, modelar e interpretar.	Mason, H., & Wiggins, C. *A Taxonomy of Data Science*.
▪ **ASUM-DM**: adaptación empresarial de CRISP-DM.	IBM Developer. *Architectural thinking in the Wild West of data science*.
▪ **DMAIC**: enfoque de mejora continua basado en datos.	American Society for Quality. *DMAIC: Define, Measure, Analyze, Improve, Control*.

Segmentación (clustering)

Caso

Una empresa desea **identificar perfiles** de empleados para comprender mejor su composición interna.

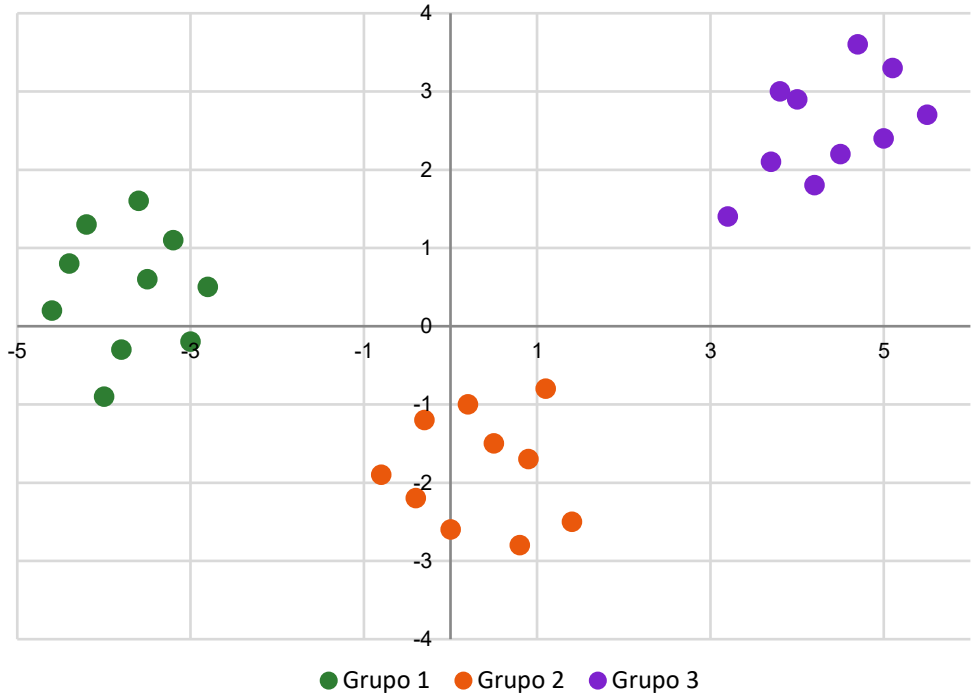
Datos de entrada

Id	Sueldo	Antig.	Hijos	Vivienda
1	1350	0.8	0	Alquiler
2	2800	5.5	1	Propia
3	4200	12.5	2	Propia
...	...	...	...	...

Entrada al algoritmo

- variables numéricas o codificadas
- registros sin etiqueta conocida

Descubrir grupos y asociaciones



Segmentación de empleados o clientes

Interpretación

- Grupo 1: jóvenes / baja antigüedad
- Grupo 2: perfil intermedio
- Grupo 3: mayor estabilidad

Técnicas

- K-means
- Jerárquico
- DBSCAN

Resultado esperado: perfiles o clusters interpretables para apoyar decisiones.

Docente: Soledad Espezúa Llerena

Reducción dimensional

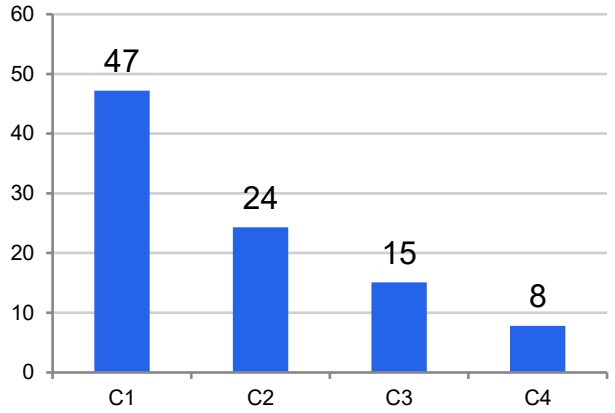
Caso

Una institución desea analizar distritos usando muchos indicadores socioeconómicos y de salud.

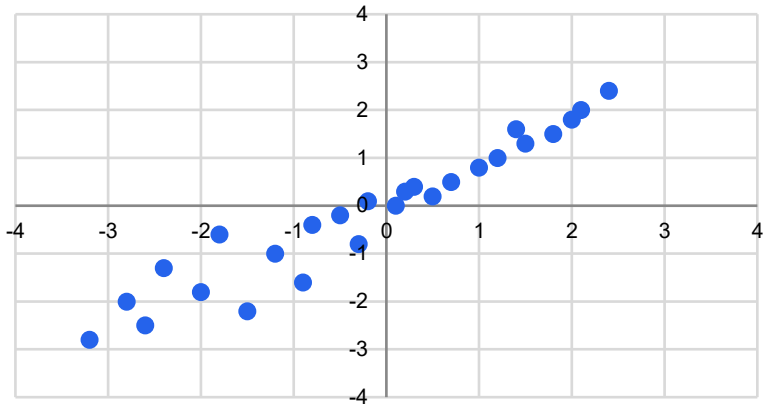
Datos de entrada

Distrito	Pobreza	Cobertura	Altitud
A	0.42	0.78	1250
B	0.35	0.65	980
C	0.61	0.48	2150
...	...	...	...

Varianza explicada



Proyección PCA



Visualización de distritos con muchos indicadores

Resumir muchas variables en pocas representaciones útiles

Problema

- muchas variables dificultan visualizar
- algunas variables están correlacionadas
- se busca una representación compacta

¿Qué se aprende?

- qué variables explican más variación
- cómo visualizar alta dimensión
- cuándo preparar datos para clustering

Técnicas frecuentes

- PCA: componentes que maximizan varianza
- NMF: factores no negativos e interpretables

Resultado esperado: pocos componentes que conserven la mayor información posible.

Docente: Soledad Espezúa Llerena

Reglas de asociación

Caso

Un supermercado desea descubrir productos que se compran juntos para diseñar promociones.

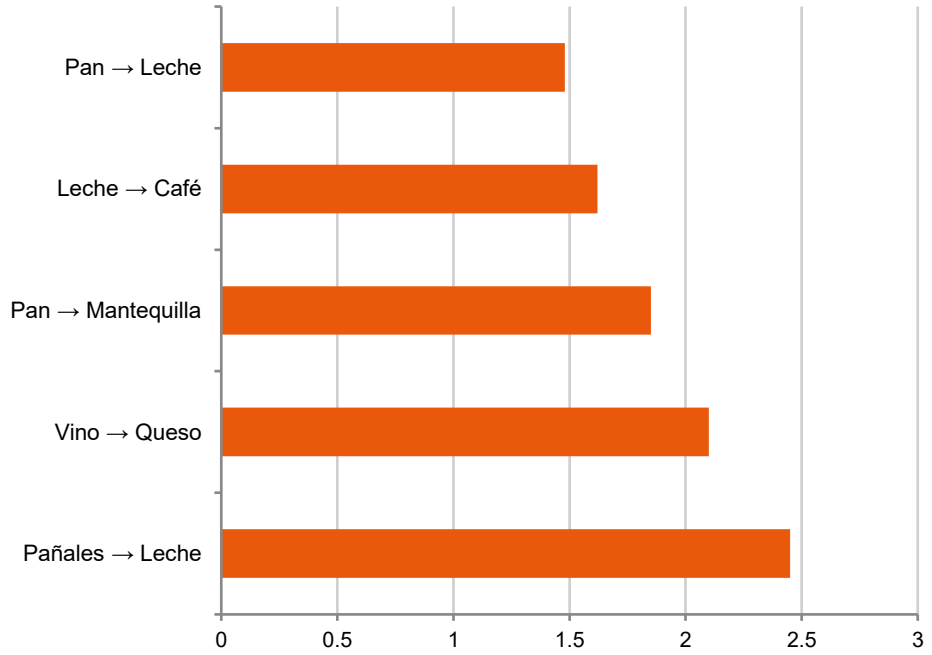
Datos de entrada

Compra	Items
1001	Pañales, Leche, Pan
1002	Vino, Queso, Pan
1003	Pañales, Leche
...	...

Medidas

- soporte: frecuencia
- confianza: probabilidad condicional
- lift: fuerza de asociación

Reglas con mayor lift



Análisis de cesta de compra

Regla	Soporte	Conf.	Lift
Pañales→Leche	0.23	0.72	2.45
Vino→Queso	0.18	0.68	2.10
Pan→Leche	0.35	0.61	1.48

Técnicas

- Apriori
- itemsets frecuentes
- reglas A → B

Descubrir elementos que suelen ocurrir juntos

Resultado esperado: reglas A → B útiles para decisiones comerciales.

Docente: Soledad Espezúa Llerena

Sistemas de recomendación

UNIVERSIDAD DEL PACÍFICO

Caso

Una plataforma digital desea recomendar libros según gustos previos y usuarios similares.

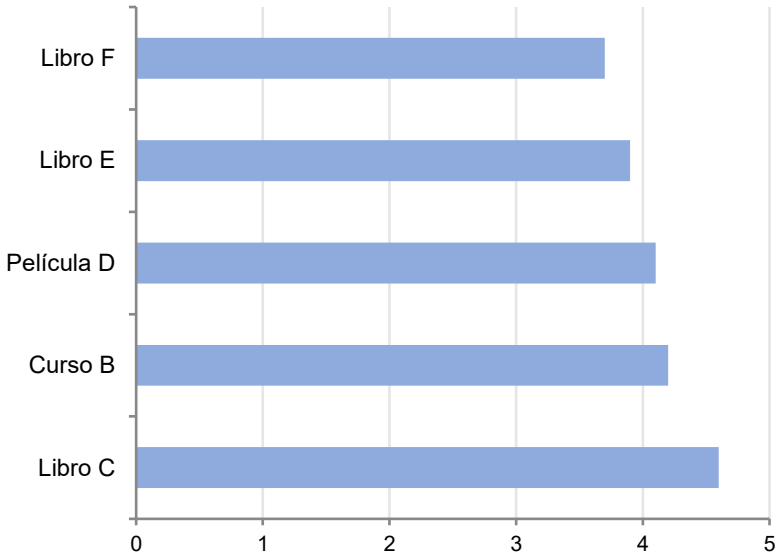
Matriz usuario–ítem

Usuario	Libro A	Libro B	Libro C
U1	5	4	
U2	4		5
U3		5	4
...	...	...	...

Idea básica

- encontrar usuarios similares
- estimar ítems no calificados
- ordenar por puntuación predicha

Top recomendados para U1



Recomendación de películas, libros o cursos

Sugerir ítems relevantes para cada usuario

Similitud entre usuarios

	U1	U2	U3	U4
U1	1.00	0.72	0.64	0.69
U2	0.72	1.00	0.61	0.58
U3	0.64	0.61	1.00	0.57
U4	0.69	0.58	0.57	1.00

Técnicas

- filtrado colaborativo basado en usuarios
- filtrado colaborativo basado en ítems
- similitud coseno

Resultado esperado: una lista personalizada de recomendaciones.

Docente: Soledad Espezúa Llerena

Detección de anomalías

Caso

Un banco desea identificar transacciones inusuales que podrían estar asociadas a fraude.

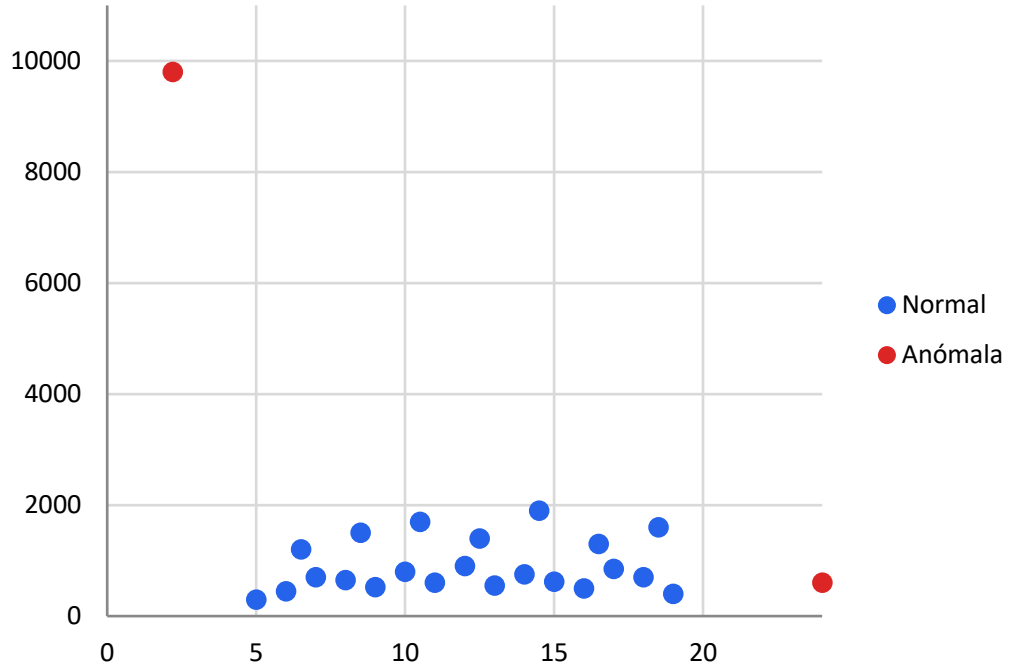
Datos de entrada

Monto	Hora	Zona
120.5	09:15	Local
9800	02:17	Internac.
60.0	03:58	Local
...	...	...

Una anomalía suele ser

- rara
- distante del patrón
- relevante para revisión

Transacciones: monto vs. hora



Caso	Razón probable
9800 / 02:17	monto alto + hora atípica
60 / 03:58	hora poco frecuente
1250 / 14:30	frecuencia inconsistente

Técnicas

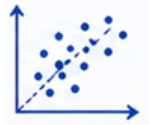
- Isolation Forest
- LOF
- DBSCAN para rareza

Identificar observaciones que se apartan del patrón normal

Resultado esperado: casos anómalos priorizados para revisión.

Tipos de problemas en Data Mining

El **problema determina** qué queremos **descubrir** en los datos.

Tipo de problema	¿Qué busca?	Ejemplo	
Segmentación	agrupar objetos similares	perfiles de empleados	
Reducción dimensional	resumir variables	visualizar distritos	
Reglas de asociación	descubrir coocurrencias	cesta de compra	
Recomendación	sugerir ítems	libros o películas	
Detección de anomalías	detectar casos raros	fraude bancario	

Lecturas complementarias

- Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). The KDD process for extracting useful knowledge from volumes of data. Communications of the ACM, 39(11), 27-34.
- Kotu, V., & Deshpande, B. (2019). Data science: concepts and practice. Morgan Kaufmann.
- Butka, P., Bednár, P., & Ivančáková, J. (2020). Methodologies for Knowledge Discovery Processes in Context of AstroGeoInformatics. In Knowledge Discovery in Big Data from Astronomy and Earth Observation (pp. 1-20). Elsevier.

UNIVERSIDAD DEL PACÍFICO

¡Gracias por su atención!