

Sesión 3

Inspección inicial de datos: estructura, variables y calidad

Docente: Soledad Espezua Llerena

s.espezual@up.edu.pe

Objetivo de la clase

- Reconocer la estructura básica de un dataset.
- Clasificar variables según su tipo, escala de medición, subtipo y rol.
- Identificar problemas frecuentes al integrar fuentes de datos.
- Reconocer mecanismos de datos faltantes y problemas de calidad que pueden afectar el análisis.

Datos estructurados

- Tienen perfectamente definido la longitud, el formato y el tamaño de sus datos.
- Se pueden administrar mediante un gestor de base de datos relacionales (como MySQL, Microsoft SQL, Oracle,…).



Base de datos relacional

empleado

IdE	*Enombre*	*Sueldo*	*Edad*	*Sexo*	*IdD*
1	Juan	2.100	45	H	Ge
2	Elena	2.400	40	M	Ma
3	María	?	53	M	Ge
4	Pedro	1.000	20	H	Ge
5	Lucía	3.500	35	M	Ma

departamento

IdD	*Dnombre*	*Director*
Ge	Gestión	Rubio
Ve	Ventas	Burriel
Ma	Márketing	Torrubia

- Filas
- Columnas
- Cabecera

- Se pueden almacenar en formato tabla, hojas de cálculo: xlsx o csv de Microsoft.



users.csv

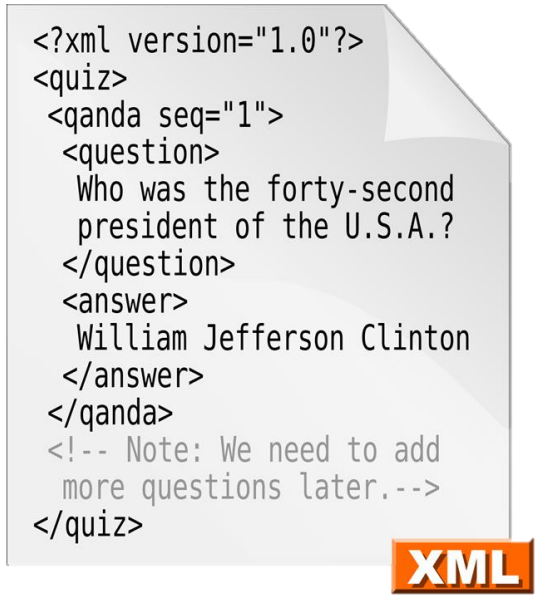
data.xlsx

Datos semiestructurados

No presenta una estructura definida, pero si una organización definida en sus metadatos donde se describen los objetos y sus relaciones.

- Ejemplo: formatos HTML, XML o JSON.







Datos no estructurados

- No siguen un esquema fijo de filas y columnas.
- Se generan en fuentes diversas, como redes sociales, documentos, páginas web, sensores y sistemas geoespaciales.
- Ejemplos: texto libre, imágenes, audio y video.

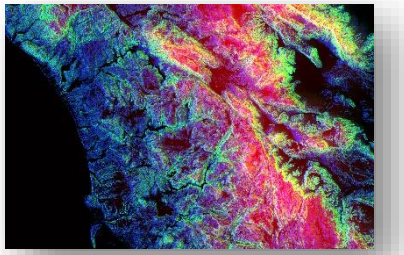




Imágenes y video



Señales de audio, radar o sonar

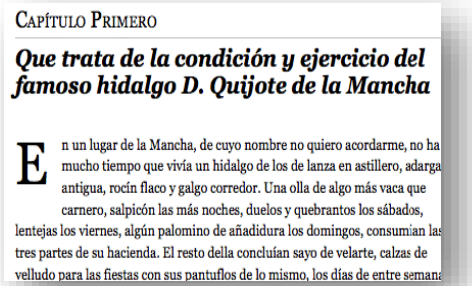




Imágenes de satélite



Web y redes sociales



CAPÍTULO PRIMERO

Que trata de la condición y ejercicio del famoso hidalgo D. Quijote de la Mancha

En un lugar de la Mancha, de cuyo nombre no quiero acordarme, no ha mucho tiempo que vivía un hidalgo de los de lanza en astillero, adarga antigua, rocín flaco y galgo corredor. Una olla de algo más vaca que carnero, salpicón las más noches, duelos y quebrantos los sábados, lentejas los viernes, algún palomino de añadidura los domingos, consumían las tres partes de su hacienda. El resto della concluían sayo de velarte, calzas de velludo para las fiestas con sus pantuflos de lo mismo, los días de entre semana

Documentos y texto libre



Video de vigilancia

Docente: Soledad Espezúa Llerena

Dataset

Un Dataset (conjunto de datos) está formado por un conjunto finito de registros u observaciones, cada uno descrito mediante un conjunto de atributos o variables.

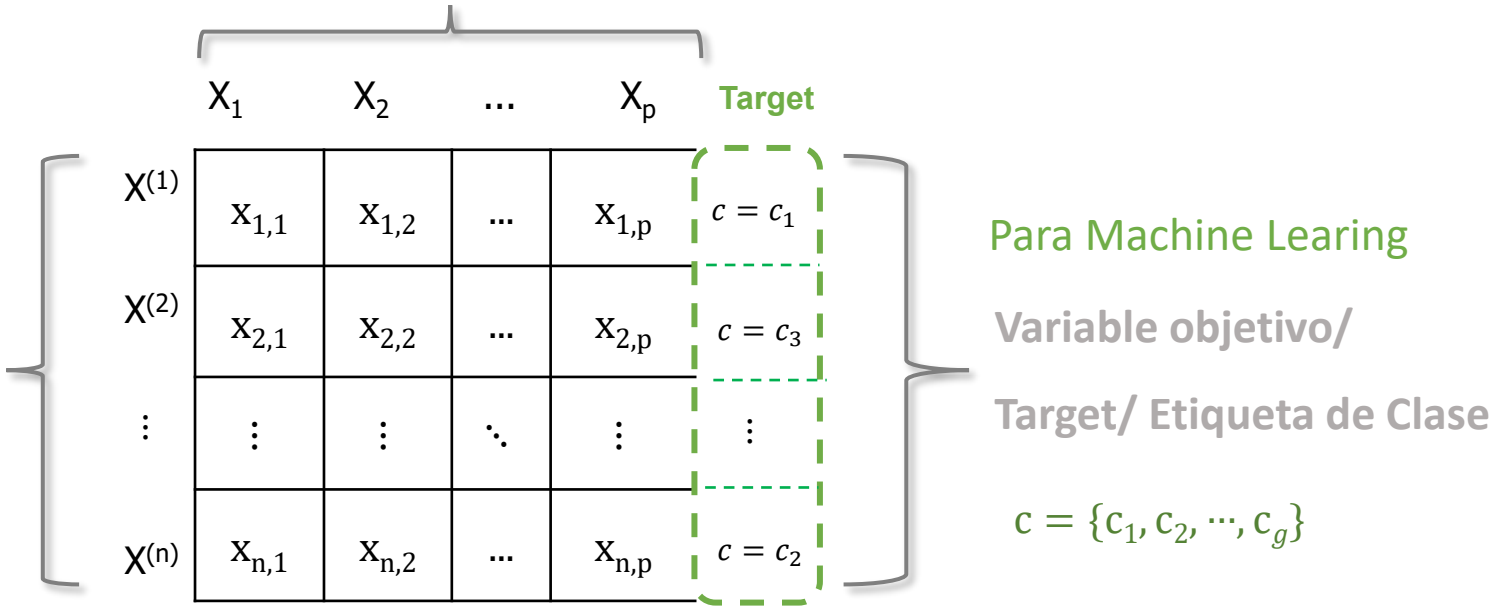
$\mathbf{X}_{n\times p}$

n = número de registros

p = número de atributos

registros / observaciones / muestras / instancias / entidades/ unidad de análisis

variables / atributos / características / dimensiones



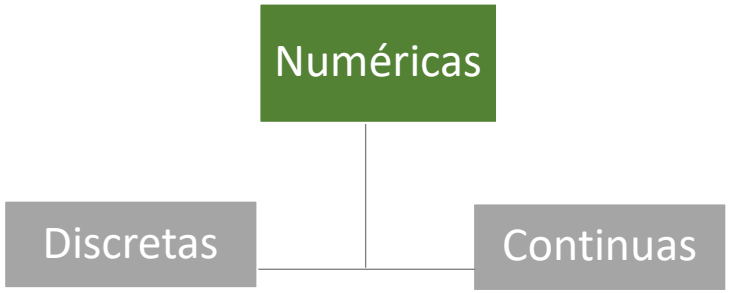
Para Machine Learing

Variable objetivo/

Target/ Etiqueta de Clase

$c = \{c_1, c_2, \cdots, c_g\}$

Tipos de variables

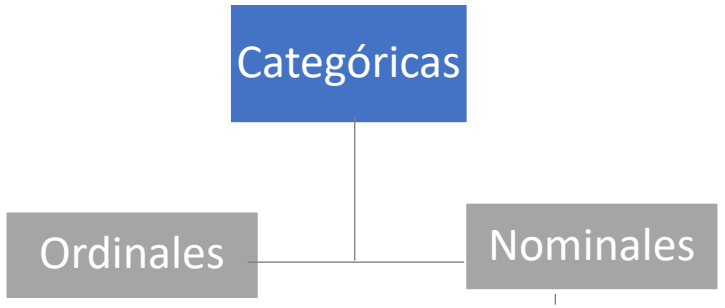


Valores contables

- Número de hijos,
- número de habitaciones

Valores medibles dentro de un intervalo

- Temperatura,
- altura



El orden importa

- Nivel: bajo, medio, alto
- Talla de ropa: S, M, L, XL

El orden no importa

- Colores: azul, rojo, blanco,…
- Estado civil: Soltero, Casado, Viudo, ..

Binarias o dicotómicas

Nota: variables **binarias** son un caso particular de variables categóricas nominales (**sin orden)**.

- Sí/No
- Presente/Ausente
- Aprobado/No aprobado

0 / 1 son códigos que representan categorías.

Nota: En sentido amplio, un atributo discreto posee un conjunto finito o contable de valores; por ello, los atributos categóricos también son discretos.

Fuente: Shreffler, J., & Huecker, M. R. (2023). Types of Variables and Commonly Used Statistical Designs. In StatPearls. StatPearls Publishing

Escalas de medición de las variables

diferencias entre valores pueden interpretarse de manera consistente

Tipo de variable	Escala	Orden	Distancias comparables	Cero absoluto	Ejemplos
Categórica	**Nominal**	No	No	No	Color, distrito, tipo de gestión, sexo, estado civil
Categórica	**Ordinal**	Sí	No	No	Nivel socioeconómico, satisfacción, talla S-M-L-XL, ranking
Numérica	**Intervalo**	Sí	Sí	No	Temperatura en °C o °F, fechas calendario
Numérica	**Razón**	Sí	Sí	Sí	Edad, peso, estatura, ingresos, número de hijos

Nominal
Clasifica en categorías sin orden natural.
Ej.: gestión pública / privada; zona urbana / rural.

Ordinal
Clasifica en categorías con orden, pero sin distancia comparable entre niveles.
Ej.: bajo / medio / alto.

Intervalo
Tiene orden y diferencias comparables, pero el cero no representa ausencia de la magnitud.
Ej.: 0 °C no significa ausencia de temperatura.

Razón
Tiene orden, diferencias comparables y cero absoluto.
Ej.: Peso: 10 gr, 0 gr (implica ausencia del objeto)
Permite comparar proporciones.
Ej.: 20 años es el doble de 10 años.

Fuente: Han, J., Pei, J., & Tong, H. (2023). Data Mining: Concepts and Techniques (4th ed.). Morgan Kaufmann. ISBN 978-0-12-811760-6.

¿Cómo clasificamos una variable?

Cada variable puede describirse indicando:

a) **Tipo general:** categórica o numérica.

b) **Escala de medición:** nominal, ordinal, intervalo o razón.

c) **Subtipo:** binaria, discreta o continua, cuando corresponda.

d) **Rol especial:** identificador, fecha, coordenada, texto, etc., cuando corresponda.

Variable	Tipo general	Escala	Subtipo/ Rol
tiene_seguro	Categórica	Nominal	Binaria
nivel_riesgo	Categórica	Ordinal	—
edad	Numérica	Razón	Discreta
ingreso_mensual	Numérica	Razón	Continua
temperatura_celsius	Numérica	Intervalo	Continua
id_cliente, dni, placa_vehiculo	Categórica	Nominal	Identificador
ubigeo	Categórica	Nominal	Código/ identificador

Importante: que un identificador esté formado por números no lo convierte en una variable numérica. Por ejemplo, id_cliente = 10025 es una **etiqueta**, no una cantidad.

El tipo de variable depende de cómo se registra

UNIVERSIDAD DEL PACÍFICO

El tipo general, depende de qué representa y cómo se registra

La **edad** es conceptualmente una variable **continua** de razón.

Sin embargo, la **variable registrada** puede ser discreta si se almacena en unidades enteras (años cumplidos, meses cumplidos o días cumplidos).

Forma de registro	Ejemplo	Clasificación
Edad exacta	20.25 años →20 1/4	Numérica — razón* — continua
Edad en años cumplidos	0, 1, 2, 3, …	Numérica — razón — discreta
Grupo de edad	bebé, niño, adulto, adulto mayor	Categórica — ordinal

La edad posee un origen natural en el nacimiento y permite comparar razones entre duraciones de vida; por ello se considera una variable de escala de razón.

Importante: La naturaleza discreta o continua de la variable registrada depende de cómo se mida y almacene..

Los números también pueden ser códigos

UNIVERSIDAD DEL PACÍFICO

Codificar con números no convierte una variable en numérica

La codificación no determina el tipo de variable

- Una variable **categórica puede representarse mediante números**.
- Los números pueden funcionar únicamente como códigos, sin significado aritmético.

Ejemplo ordinal

Nivel de riesgo: `1 = Bajo; 2 = Medio; 3 = Alto`

→ **Tipo:** categórica ordinal

→ El orden importa, pero no podemos asumir que la distancia entre 1 y 2 sea igual a la distancia entre 2 y 3.

Ejemplo binario

Tiene seguro: `0 = No; 1 = Sí`

→ **Tipo:** categórica nominal

→ **Subtipo:** binaria/dicotómica

→ 0 y 1 son códigos de las categorías.

- **Tipos de variables**
  Numéricas / categóricas → discretas, continuas, nominales, ordinales, binarias.
- **Escalas de medición**
  Nominal / ordinal / intervalo / razón.
- Tipo de variable ≠ codificación

Una misma característica puede generar distintas variables

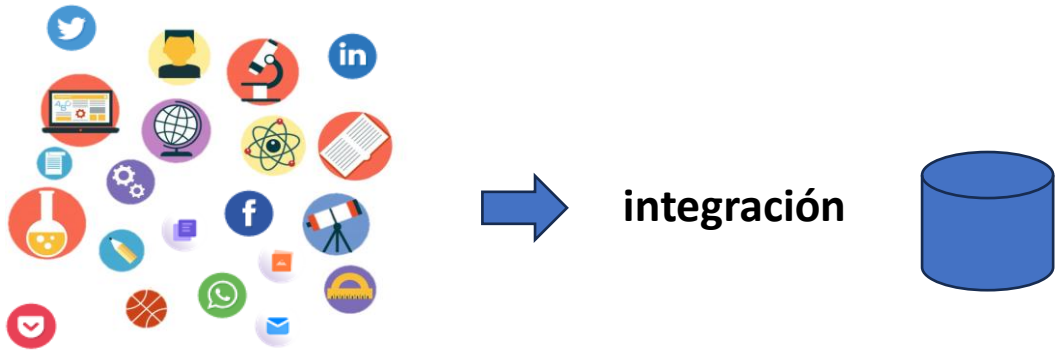
El mismo concepto puede convertirse en variables diferentes según cómo se mida, registre o agrupe.

Por ejemplo, el concepto “salario” puede registrarse como:

Forma de registro	Ejemplo	Clasificación
Salario exacto	S/ 2 350.75	Numérica — razón — continua*
Salario redondeado a centenas	1000, 1100, 1200, ..	Numérica — razón — discreta
Nivel de salario	bajo / medio / alto	Categórica — ordinal

En las dos primeras formas de registro, la escala es de razón: existe un cero significativo y las proporciones tienen sentido.

Integración de fuentes de datos



Fuente: Han, J., Pei, J., & Tong, H. (2023). Data Mining: Concepts and Techniques (4th ed.). Morgan Kaufmann. ISBN 978-0-12-811760-6.

Docente: Soledad Espezúa Llerena

Problemas al integrar fuentes de datos

Al combinar fuentes que describen las mismas entidades, pueden aparecer conflictos que deben resolverse antes del análisis:

Problema	Descripción
Datos faltantes	Un dato está presente en una fuente, pero ausente en otra.
Datos inconsistentes	El mismo atributo tiene valores diferentes entre fuentes.
Datos redundantes	Dos atributos contienen la misma información.
Datos parcialmente redundantes	Dos atributos están relacionados, pero no son equivalentes.

Integrar datos no es solo unir tablas: también implica detectar ausencias, conflictos y duplicidades.

Problemas al integrar fuentes de datos

Integrar datos no es solo unir tablas: también implica resolver ausencias, conflictos y redundancias entre fuentes.

DNI	EDAD	COD.POSTAL	ESTADO	AÑOS_CARNÉ
...	....	...	...	...
25342135	35	46019	Casado	13
98525925	23	28004	Soltero	1
...	....	...	...	...

DNI	FECHA_NAC	CIUDAD	CASADO	CARNÉ
...	....	...	...	...
77775252	1/1/1950	Benitatxell	SÍ	A2
25342135	18/11/1971	Valencia	NO	B1
...	....	...	...	...

Fuente 1

Fuente 2

DNI	EDAD	FECHA_NAC	CIUDAD	COD_POSTAL	ESTADO	CASADO	AÑOS_CARNÉ	CARNÉ
...		....	...			...		...
25342135	35	18/11/1971	Valencia	46019	Casado	NO	13	B1
98525925	23	-	-	28004	Soltero	-	1	-
77775252	-	1/1/1950	Benitatxell	-	-	SÍ	-	A2
...		....	...			...		...

i) datos faltantes:

"edad", "fecha_nac","ciudad", "cod_postal", "estado","casado", "años_carné", "carné"

ii) datos inconsistentes:

DNI: 25342135

→ Fuente1: Casado

→ Fuente2: Casado NO!

En muchos casos los datos inconsistentes se tratan provisionalmente como valores faltantes hasta resolver la discrepancia

iii) Datos redundantes:
"edad" y "fecha_nac"

iv) Datos parcialmente redundantes:
"ciudad" y "cod_postal",
"estado" y "casado"

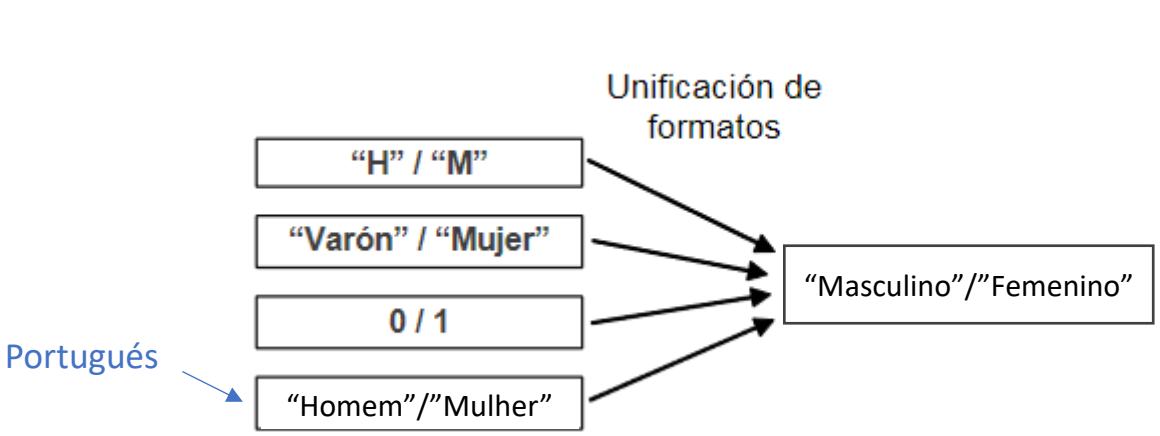
ESTADO	CASADO
Casado	Sí
Soltero	No
Viudo	No
Divorciado	No

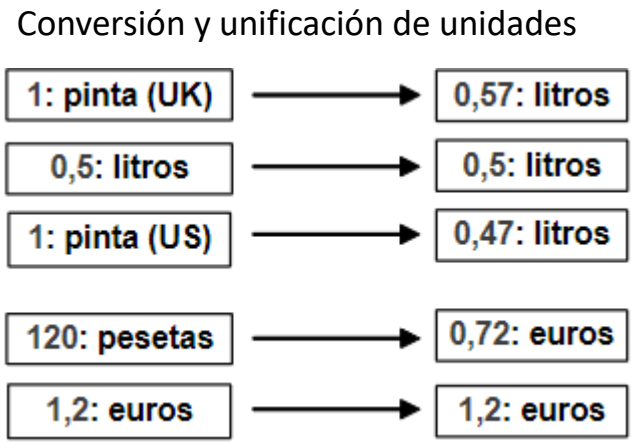
CASADO puede derivarse parcialmente de **ESTADO**, pero no contiene toda la misma información.

Fuente: Han, J., Pei, J., & Tong, H. (2023). Data Mining: Concepts and Techniques (4th ed.). Morgan Kaufmann. ISBN 978-0-12-811760-6.

Problemas al integrar fuentes de datos

- Cuando se integran datos provenientes de distintas fuentes, es común encontrar diferencias en codificaciones, idiomas, unidades de medida y zonas horarias. Por ello, es necesario **unificar formatos y medidas**.





Ejemplos de integración: unificación de formatos y medidas.

Tipos de datos faltantes

Tipo	¿De qué depende la ausencia?	Ejemplo	Implicancia
MCAR *Missing Completely At Random*	No depende de los datos observados ni de los valores faltantes.	Un sensor deja de registrar por una falla eléctrica aleatoria.	Es el caso menos problemático. Eliminar registros puede no introducir sesgo importante.
MAR *Missing At Random*	Depende de variables observadas.	La falta de valores en “peso” puede estar asociada a “edad” o “sexo”, variables que sí están registradas.	Puede tratarse usando imputación o modelos que usen las variables observadas.
MNAR *Missing Not At Random*	Depende del propio valor faltante.	Personas con ingresos muy bajos/altos omiten reportar salario; pacientes con depresión severa no completan cuestionarios.	Es el caso más difícil. Puede introducir sesgo serio si no se modela explícitamente.

Fuente: Han, J., Pei, J., & Tong, H. (2023). Data Mining: Concepts and Techniques (4th ed.). Morgan Kaufmann. ISBN 978-0-12-811760-6.

Resumen de fuentes antes de la integración

La tabla resumen permite comparar los atributos de cada fuente antes de integrarlas.
Ayuda a detectar diferencias en nombres, tipos de datos, valores faltantes, valores distintos, rangos, categorías sospechosas y posibles inconsistencias entre fuentes.

Valores distintos

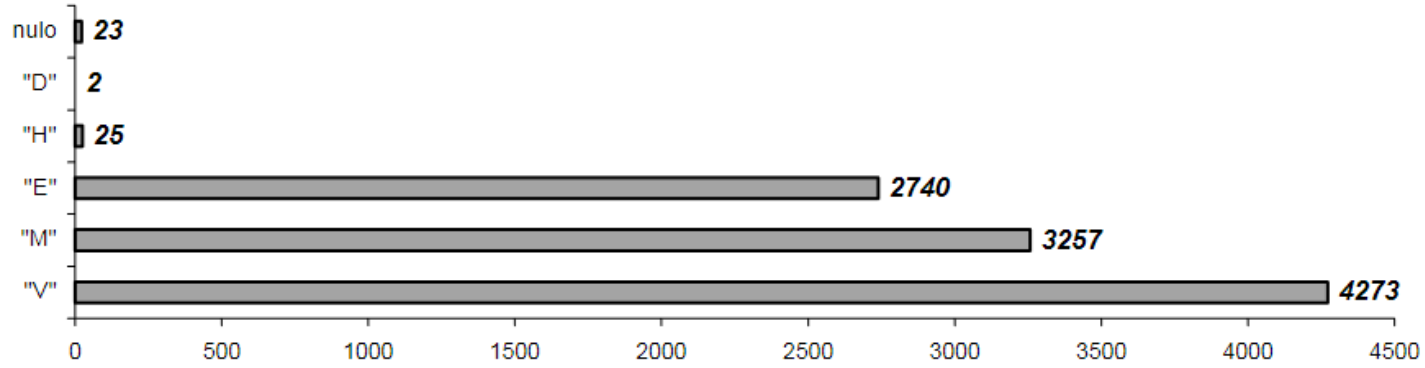
Atributo	Tabla	Tipo	# total	# nulos	# dists	Media	Desv.e.	Moda	Min	Max
Código postal	Cliente	Nominal	10320	150	1672	-	-	"46003"	"01001"	"50312"
Sexo	Cliente	Nominal	10320	23	6	-	-	"V"	"E"	"M"
Estado civil	Cliente	Nominal	10320	317	8	-	-	Casado	"Casado"	"Viudo"
Edad	Cliente	Numérico	10320	4	66	42,3	12,5	37	18	87
Total póliza p/a	Póliza	Numérico	17523	1325	142	737,24€	327€	680€	375€	6200€
Asegurados	Póliza	Numérico	17523	0	7	1,31	0,25	1	0	10
Matrícula	Vehículo	Nominal	16324	0	16324	-	-	-	"A-0003-BF"	"Z-9835-AF"
Modelo	Vehículo	Nominal	16324	1321	2429	-	-	"O. Astra"	"Audi A3"	"VW Polo"
...	...	...	...	...	...	...	...	...	...	...

¿Qué permite revisar?

- Atributos presentes en cada fuente.
- Cantidad de nulos y valores distintos.
- Tipos de datos y formatos.
- Categorías inesperadas o mal codificadas.
- Rangos mínimos y máximos sospechosos.

Ejemplo: si el atributo "sexo" tiene 6 valores distintos, la fuente puede contener categorías válidas, códigos especiales o errores de codificación que deben revisarse antes de integrar los datos.

Gráfico de barras representando las frecuencias del atributo "sexo".



Problemas frecuentes de calidad de datos

UNIVERSIDAD DEL PACÍFICO

- **Reglas de negocio incumplidas**

  Ej.: registros de licencia de conducir para menores de 18 años.

- Datos **inconsistentes**: Valores que se contradicen entre sí dentro del mismo registro o entre fuentes distintas.

  Ej.: un recibo registra consumo eléctrico = 0 kWh, pero también registra importe por consumo = S/ 120.

  Ej.: una persona aparece como **menor de edad**, pero también como **jubilada**.

- Formatos **no uniformes**

  Ej.: fechas registradas como dd-mm-yyyy en algunos casos y yyyy/mm/dd en otros.

- Valores **inválidos**

  Ej.: una variable que solo admite A o B, pero registra C.

- Datos **duplicados**

  Ej.: una cita médica aparece dos veces con el mismo cliente, servicio, fecha, hora y código de transacción.

Posibles estrategias: corregir, estandarizar, imputar, consolidar o eliminar según el caso.

UNIVERSIDAD DEL PACÍFICO

¡Gracias por su atención!