

Sesión 4
Limpieza inicial de datos

Docente: Soledad Espezua Llerena

s.espezual@up.edu.pe

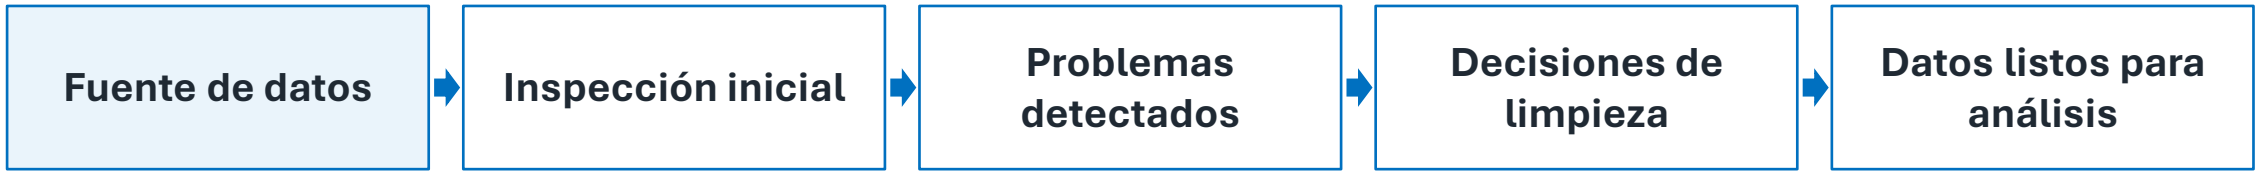
Objetivo de la clase

- Aprender a reconocer los problemas de calidad más comunes en un conjunto de datos y a decidir cómo tratarlos antes de analizar o modelar.
- Distinguir cuatro acciones distintas: detectar, corregir, imputar y eliminar.
- Practicar el tratamiento básico de valores faltantes y aprender a justificar cada decisión.

Una base limpia no es una base perfecta: es una base revisada, documentada y defendible.

Inspección inicial

La limpieza empieza después de entender qué representa cada variable y sigue una secuencia de trabajo:



Paso	Acción	Pregunta
1	Inspeccionar	¿Qué estructura, columnas y tipos tengo?
2	Detectar	¿Dónde hay nulos, errores, duplicados u outliers?
3	Decidir	¿Conviene corregir, imputar, eliminar o conservar?
4	Aplicar	¿Qué cambio haré?
5	Justificar	¿Por qué esa decisión es defendible?

Durante la limpieza	Después de limpiar
Corrijo tipos, unifico categorías, reviso faltantes, duplicados y valores inválidos.	Valido que los datos sean más coherentes y **documento** lo realizado.

Ejemplo: un ingreso muy alto puede ser error, caso especial o información relevante. La decisión depende del dominio.

Estadísticas descriptivas básicas

Primera mirada a variables numéricas y categóricas

Python	Qué ayuda a revisar
shape	Cantidad de filas y columnas
dtypes	Tipos detectados por Python
describe()	Conteos, valores únicos, media, desviación, mínimos, máximos y cuartiles
describe(include="all")	También resume variables categóricas o de texto

- describe() ayuda a revisar:
  - ❑ cantidad de datos no nulos.
  - ❑ media, mediana aproximada y dispersión.
  - ❑ valores mínimos y máximos.
  - ❑ categorías más frecuentes.
  - ❑ valores únicos en variables categóricas.

Decisión: ¿el dato es válido, sospechoso o imposible?

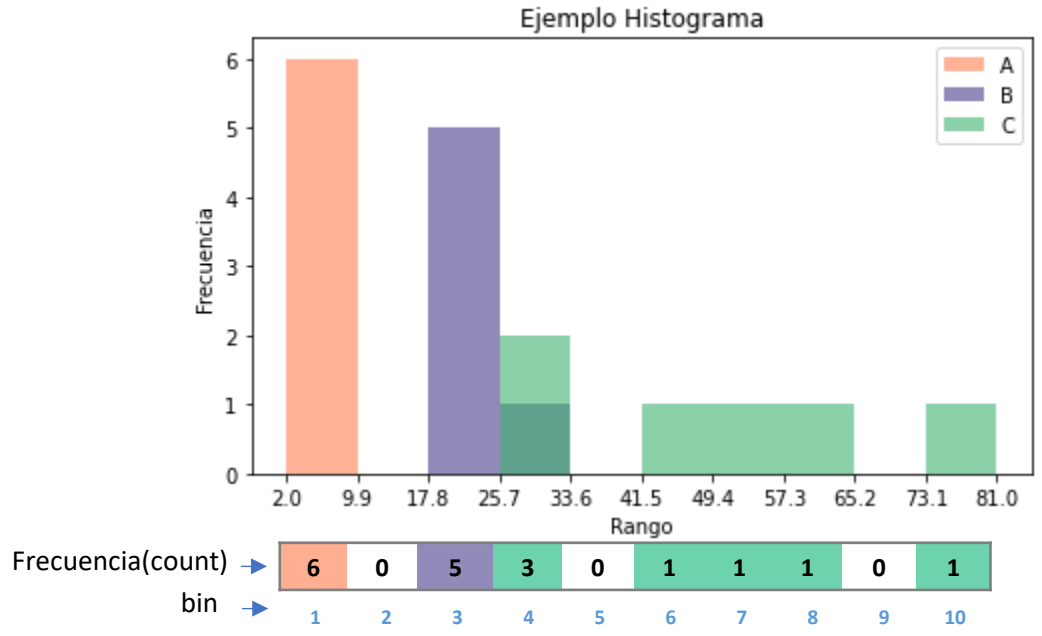
	preg	plas	pres	skin	test	mass	pedi	age	class
Cantidad de valores	768.000	768.000	768.000	768.000	768.000	768.000	768.000	768.000	768.000
Media	3.845	120.895	69.105	20.536	79.799	31.993	0.472	33.241	0.349
Desviación Standar	3.370	31.973	19.356	15.952	115.244	7.884	0.331	11.760	0.477
Mínimo Valor	0.000	0.000	0.000	0.000	0.000	0.000	0.078	21.000	0.000
1er cuartil → 25th Percentil	1.000	99.000	62.000	0.000	0.000	27.300	0.244	24.000	0.000
Mediana → 50th Percentil	3.000	117.000	72.000	23.000	30.500	32.000	0.372	29.000	0.000
3er cuartil → 75th Percentil	6.000	140.250	80.000	32.000	127.250	36.600	0.626	41.000	1.000
Máximo Valor	17.000	199.000	122.000	99.000	846.000	67.100	2.420	81.000	1.000

Keim, R. (2020) Understanding Parametric Tests, Skewness and Kurtosis. https://www.allaboutcircuits.com/technical-articles/understanding-thenormal-distribution-parametric-tests-skewness-and-kurtosis/

Estadísticas descriptivas básicas

- Histograma: ¿cómo se distribuyen los datos?
  - Muestra la **distribución de frecuencias** de valores de una **variable numérica**.
  - Agrupa los datos en **intervalos** "*bins*".
  - La altura de cada barra indica la frecuencia en cada intervalo.
  - Permite observar:
    - concentración de valores;
    - valores muy frecuentes;
    - posibles valores extremos;
    - forma general de la distribución

edad
6
7
5
2
2
2
21
26
22
22
24
24
28
30
42
62
81
50

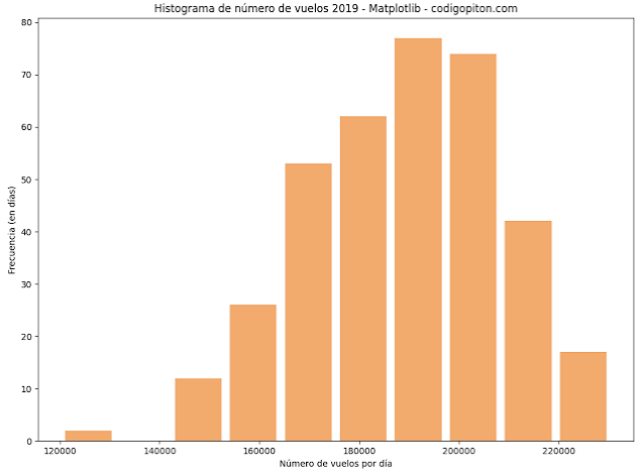



```
df["edad"].hist()
```

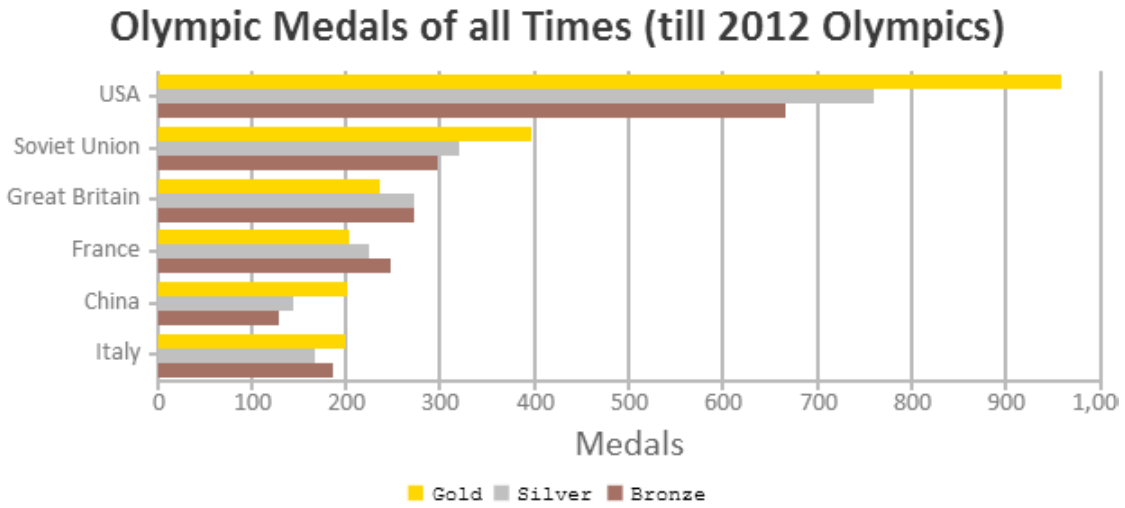
Estadísticas descriptivas básicas

Histograma vs. gráfico de barras

- Histograma: distribución de una variable numérica en intervalos.
- Barras: compara categorías.
- Histograma: intervalos ordenados
- Barras: categorías reordenables; en el histograma no.



Histogram



Bar chart

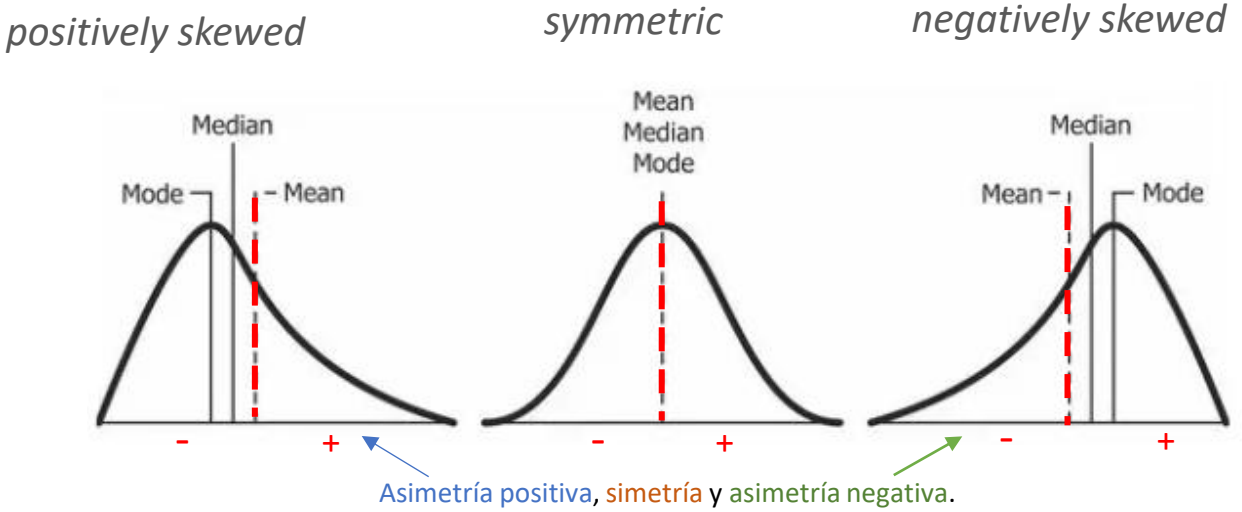
Estadísticas descriptivas básicas

- *Skewness*

Asimetría (*Skewness*) ayuda a identificar si una **distribución** de datos está **sesgada.**

```
data.skew()
```

Asimetría positiva moderada	preg	0.901674
Casi simétrica	plas	0.173754
Fuerte asimetría negativa	pres	-1.843608
Casi simétrica	skin	0.109372
Fuerte asimetría positiva	insu	2.272251
Ligera asimetría negativa	mass	-0.428982
Fuerte asimetría positiva	pedi	1.919911
Asimetría positiva importante	age	1.129597



Keim, R. (2020) Understanding Parametric Tests, Skewness and Kurtosis. https://www.allaboutcircuits.com/technical-articles/understanding-thenormal-distribution-parametric-tests-skewness-and-kurtosis/

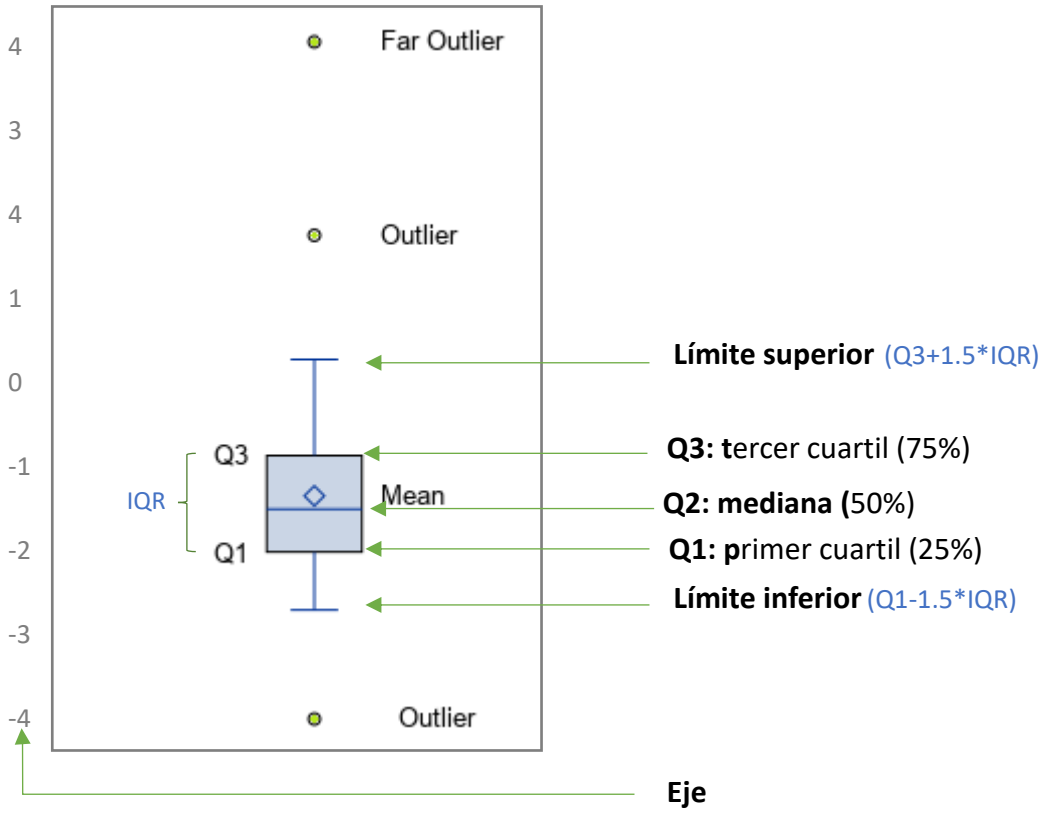
Estadísticas descriptivas básicas

- BoxPlot (diagrama de caja y bigotes)

Permite visualizar la distribución de una variable a partir de la mediana, los cuartiles y los posibles valores atípicos (*outliers*).

Caso	Decisión posible
Valor imposible	Corregir o eliminar
Valor raro pero posible	Mantener y justificar
Error de registro	Consultar la fuente o convertir a faltante

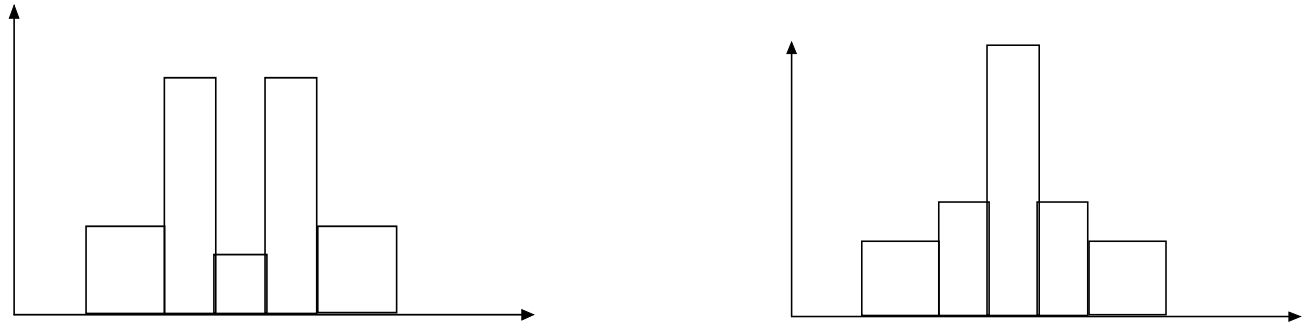
Diagrama esquemático



Keim, R. (2020) Understanding Parametric Tests, Skewness and Kurtosis. https://www.allaboutcircuits.com/technical-articles/understanding-thenormal-distribution-parametric-tests-skewness-and-kurtosis/

Estadísticas descriptivas básicas

- Los histogramas suelen decir más que los diagramas de caja (boxplots)



- Los dos histogramas pueden tener el mismo boxplot.
- Comparten los mismos valores: mínimo, Q1, mediana, Q3 y máximo.
- Pero tienen distribuciones de datos bastante distintas.

Keim, R. (2020) Understanding Parametric Tests, Skewness and Kurtosis. https://www.allaboutcircuits.com/technical-articles/understanding-thenormal-distribution-parametric-tests-skewness-and-kurtosis/

Ejercicio: encontrar errores en una base

- Antes de programar, miremos la base como analistas.
- Por lo menos hay 12 errores

ID	Salario	Calificación	Sexo	Edad	Bono	EstCivil
101	6000	10	F	35	200	S
102	8000	4	F	40	100	S
103	15000000		F	40	300	S
104	5000	0	M	V	400	C
105	100	5	M	50	3.10E+03	C
106	3000		H	20	500	V
104	-2000	8	H	15	100	S

¿qué problemas pueden afectar el análisis si no se corrigen?

Ejercicio: encontrar errores en una base

Antes de programar, miremos la base como analistas.

ID	Salario	Calificación	Sexo	Edad	Bono	EstCivil
101	6000	10	F	35	200	S
102	8000	4	F	40	100	S
103	15000000		F	40	300	S
104	5000	0	M	V	400	C
105	100	5	M	50	3.10E+03	C
106	3000		H	20	500	V
104	-2000	8	H	15	100	S

Duplicados

¿Salarios de este valor son permitidos?

¿Cómo tratamos un vacío?

¿Cómo tratar inconsistencias?

¿Un menor de edad trabajando?

¿String y enteros?

¿S=Soltero?
¿S=Separado?

¿C=Casado?
¿C=Conviviente?

Tipos de problemas de calidad de datos

Problema	Ejemplo	Decisión inicial
Valores faltantes	edad vacía, distrito no registrado	imputar, eliminar o revisar fuente
Duplicados	mismo cliente repetido	consolidar o eliminar
Tipos incorrectos	edad como texto	convertir tipo
Categorías no estandarizadas	M, Masculino, masc	homologar categorías
Valores fuera de rango	edad = 250	corregir o marcar como faltante
Inconsistencias	consumo = 0 y cobro > 0	validar regla de negocio

Detectar el problema es solo la mitad del trabajo; la otra mitad es **justificar** la decisión.

Conversión de tipos y formatos

Algunos datos se cargan con un tipo incorrecto. Antes de limpiar, hay que revisar qué representa cada variable.

```
df["fecha"] = pd.to_datetime(df["fecha"], errors="coerce")
df["edad"] = pd.to_numeric(df["edad"], errors="coerce")
```

Situación	Interpretación
object	Generalmente texto o categorías; también puede indicar mezcla de valores
int64 / float64	Números detectados por Python
datetime	Fecha reconocida como fecha
errors="coerce"	Convierte valores no válidos a NaN para identificarlos y revisarlos

Edad		Edad
35		35
40		40
40		40
V	→	**NaN**
50		50

Estandarización de nombres y categorías

Un mismo valor puede aparecer escrito de varias formas.

```
df["sexo"].value_counts(dropna=False)

df["sexo"] = df["sexo"].replace({
    "M": "Masculino",
    "masc": "Masculino",
    "F": "Femenino"
})
```

→ no se deben excluir los valores faltantes (NaN) del resultado

contará también los NaN:

Femenino	120
Masculino	100
NaN	15

Antes	Después
M	Masculino
masc	Masculino
F	Femenino
Femenino	Femenino
NaN	NaN o “No registrado”

```
df["edad"] = df["edad"].where(df["edad"] >= 18, np.nan)
```

Significa:

- si `edad >= 18` → mantiene la edad;
- si `edad < 18` → reemplaza por `NaN`.

Duplicados e inconsistencias

Un registro repetido no siempre se elimina automáticamente.

```
df.duplicated().sum()   → cuenta cuántos duplicados hay
df[df.duplicated(subset=["id"], keep=False)] → muéstralos, marcando incluso la primera aparición
df.drop_duplicates()    → elimínalos
```

Tipo de caso	Qué hacer
Fila duplicada exacta	Eliminar una de las copias
ID duplicado con datos diferentes	Revisar cuál registro es correcto o cómo consolidarlos
Inconsistencia entre variables	Validar reglas del negocio

Ej.: Cliente 101, edad 35 y luego cliente 101, edad 52 → posible **inconsistencia** si ambas filas describen al mismo cliente en el mismo momento.

Un cliente aparece como menor de edad, pero registra una cuenta o contrato que exige mayoría de edad.

La clave (ID) define si un duplicado es un error o un evento legítimo.

Tratamiento básico de valores faltantes

Estrategia	Cuándo puede usarse
Eliminar fila	Pocos casos y bajo impacto
Eliminar columna	Demasiados faltantes o variable poco útil
Media	Variable numérica sin muchos outliers
Mediana	Variable numérica con outliers
Moda	Variable categórica
Valor contextual	Cuando existe una regla del dominio

Toda imputación debe poder explicarse.



Pérdida de datos



Altera la distribución de los datos

edades: 21, 22, 23, 25, 70
media = 32.2
mediana = 23

```
df["edad"].fillna(df["edad"].median())
df["distrito"].fillna(df["distrito"].mode()[0])
df.dropna()
```

Estrategia	Cuándo
Media	Distribución aproximadamente simétrica y sin outliers importantes
Mediana	Distribución asimétrica o con outliers

No hay una técnica universal.

- Depende del porcentaje de faltantes.
- Depende de la variable.
- Depende del mecanismo de ausencia.
- Depende del contexto del problema.

UNIVERSIDAD DEL PACÍFICO

¡Gracias por su atención!