

Sesión 5
Introducción-Visualización

Docente: Soledad Espezua Llerena

s.espezual@up.edu.pe

Objetivo de la clase

- Entender para qué sirve la visualización en el análisis de datos, seleccionar gráficos básicos según el tipo de variable
- Validar una base integrada antes de usarla en su primer hito del proyecto.

¿Qué es visualización de datos?

"Visualización es la representación y presentación de datos para facilitar su comprensión"

Adaptado de Kirk (2016)

"La visualización de datos facilita una comprensión rápida de los datos, permitiendo identificar patrones, tendencias y relaciones"

Adaptado de Ozdemir (2016)



John W. Tukey

"El mayor valor de una representación gráfica está en que nos obliga a notar aquello que no esperábamos ver"

Adaptado Tukey (1977).

- Kirk, A. Data Visualisation: A handbook for Data Driven Design. SAGE publications, 2016.
- Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.
- Ozdemir, S. (2016). Principles of Data Science. Packt Publishing.

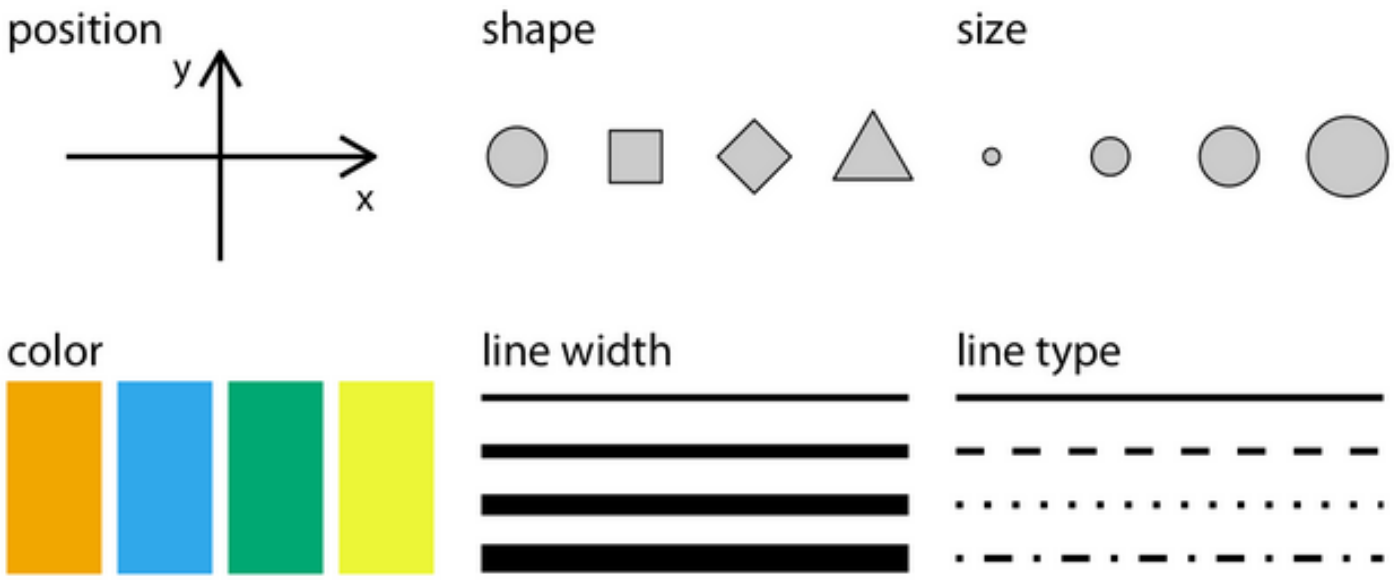
La buena visualización

Permite:

- Explorar: encontrar patrones, tendencias y valores atípicos.
- Comunicar: condensar información y hacerla comprensible
- Inspira nuevas preguntas que requieren mayor exploración
- Decidir: apoyar decisiones basadas en evidencia



¿Cuántas variables se pueden visualizar?

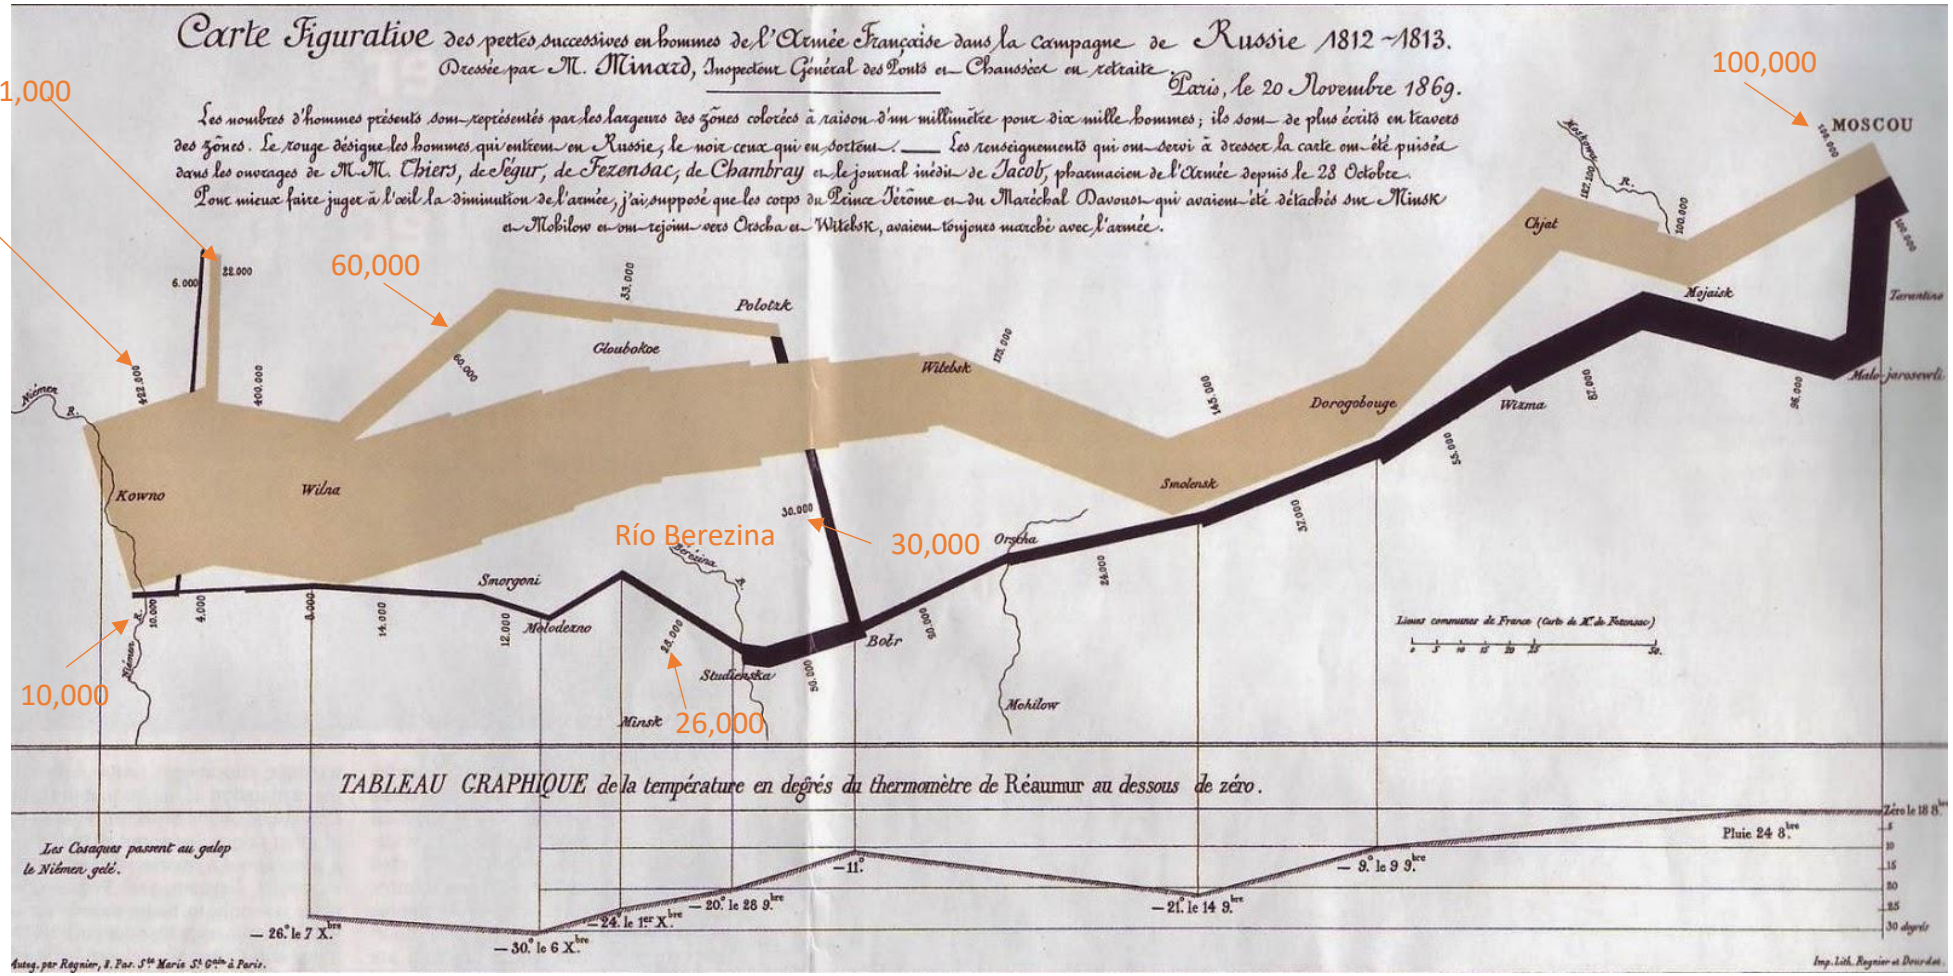


Fuente: Claus O. Wilke (2019). *Fundamentals of Data Visualization*

Visualizaciones Memorables

Ejército de Napoleón en la campaña hacia Rusia de 1812. Indica la ubicación del ejército (eje X) y una tabla inferior de temperaturas (valores bajo el punto de congelación).

Una buena visualización no muestra todo: muestra lo necesario para entender una historia.



Campaña a Rusia del ejército de Napoleón en 1812 (Charles Minard, 1869)

Fuente: Michael Friendly,2007. A Brief History of Data Visualization. In Handbook of Computational Statistics: Data Visualization. III. Springer-Verlag. Heidelberg. 1-34.

Visualizaciones Memorables

1700-1799: Nuevas formas gráficas

Combinación de círculos y líneas, para demostrar que los ***impuestos per cápita*** de los británicos estaban sobrecargados en comparación con otras naciones.

Autor:

- William Playfair, inventor de muchas de las gráficas más populares que usamos actualmente (líneas, barras, círculos y gráficas circulares).
- Invento de gráficos estadísticos: histogramas, series temporales, contorno, dispersión y otros.

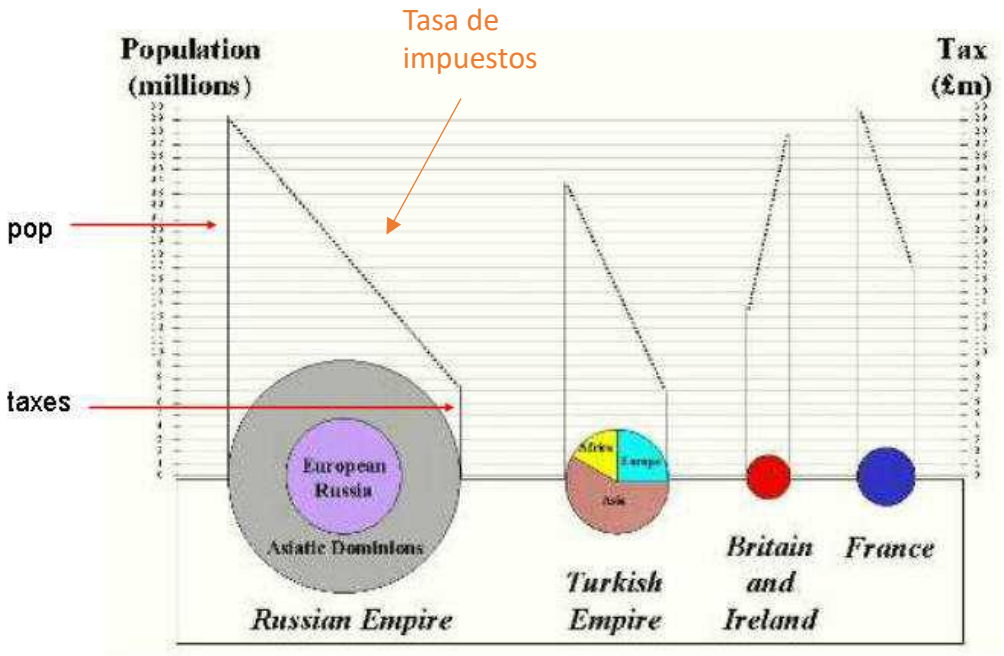


Figure 6: Re-drawn version of a portion of Playfair's 1801 pie-circle-line chart, comparing population and taxes in several nations.

Fuente: Michael Friendly,2007. A Brief History of Data Visualization. In Handbook of Computational Statistics: Data Visualization. III. Springer-Verlag. Heidelberg. 1-34.

Visualizaciones Memorables

1800-1850: Surgimiento de los gráficos estadísticos

Evolución del precio del trigo y de los salarios semanales, junto con los reinados de los monarcas ingleses, durante aproximadamente 250 años (1565–1820).

Autor:

William Playfair, (1821)
A Letter on Our Agricultural Distresses, Their Causes and Remedies.

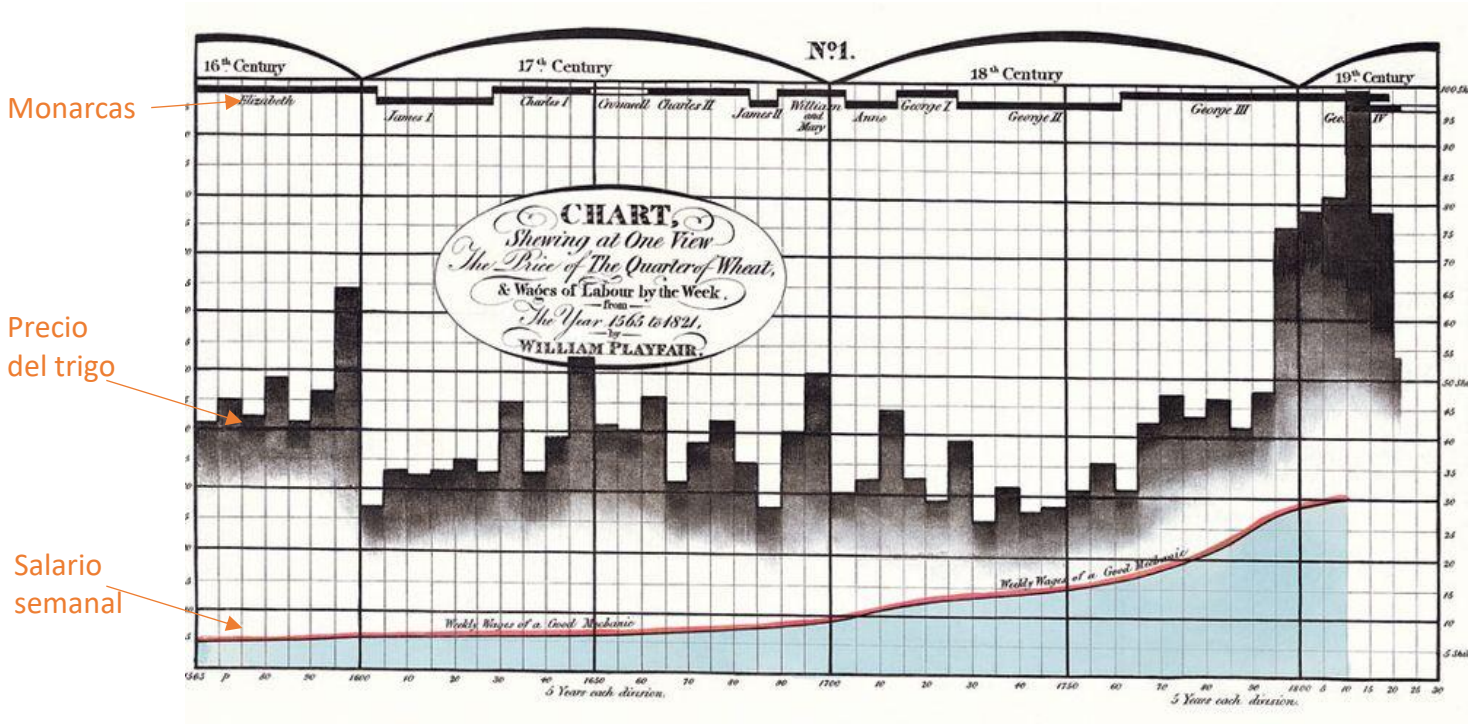


Figure 7: William Playfair's 1821 time series graph of prices, wages, and ruling monarch over a 250 year period. *Source*: Playfair (1821), image from Tufte (1983, p. 34)

Fuente: Michael Friendly,2007. A Brief History of Data Visualization. In Handbook of Computational Statistics: Data Visualization. III. Springer-Verlag. Heidelberg. 1-34.

Visualizaciones Memorables

1850-1900: La era dorada de las tablas estadísticas

- Gráfico de barras consecutivas, para mostrar la relación entre inmigración/ emigración en los 49 estados de Estados Unidos.

Datos basados en el censo de 1980 (EEUU).

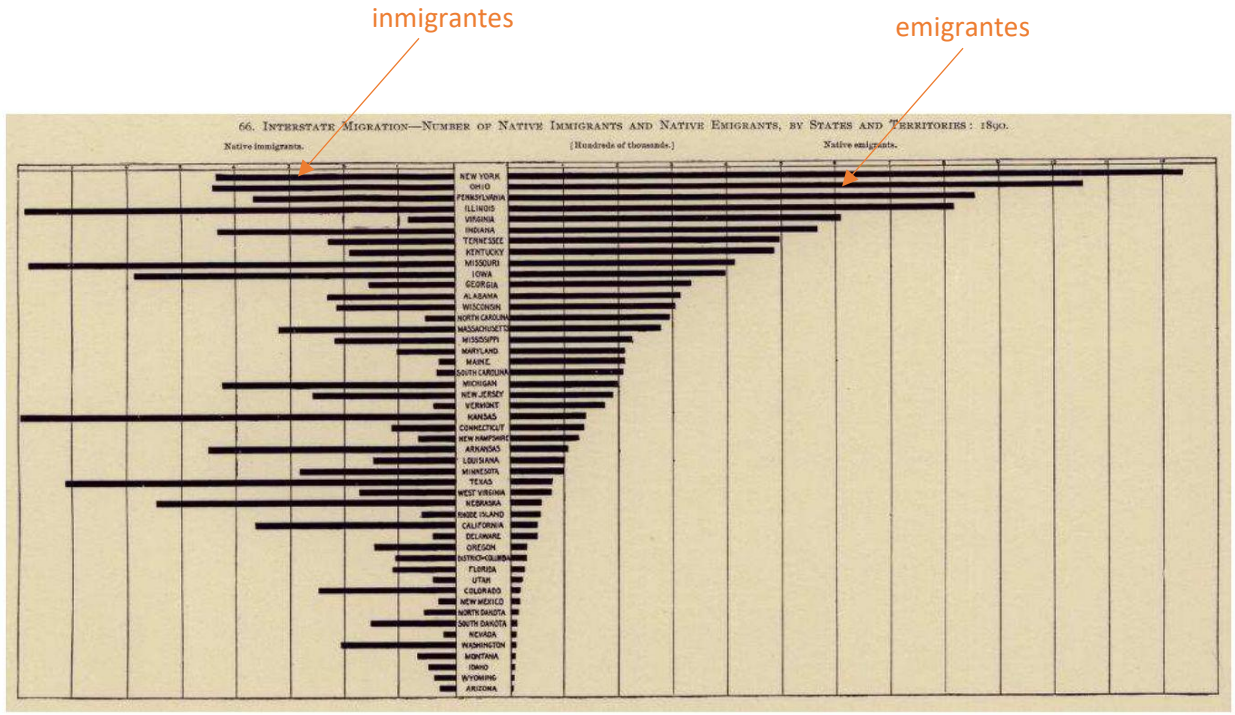


Figure 13: Interstate migration shown by back-to-back bar charts, sorted by emigration. *Source*: Statistical Atlas of the Eleventh Census, 1890, diagram 66, p. 23 (author's collection).

Figure 11: One page of Galton's 1863 multivariate weather chart of Europe showing barometric pressure, wind direction, rain, and temperature for the month of December, 1861. *Source*: Pearson (1930, pl. 7).

Fuente: Michael Friendly,2007. A Brief History of Data Visualization. In Handbook of Computational Statistics: Data Visualization. III. Springer-Verlag. Heidelberg. 1-34.

Visualizaciones Memorables

1950-1970: Renacimiento de la visualización de datos

- Diagrama de caja (‘box-plot’), usado para comparar los puntos más altos de cada estado de EEUU y las altitudes de algunos volcanes.

Autor:

- John W. Tukey, (1977): “*Exploratory Data Analysis*” (EDA).
- Creador de stem-leaf plots, boxplots, two-way table, etc.

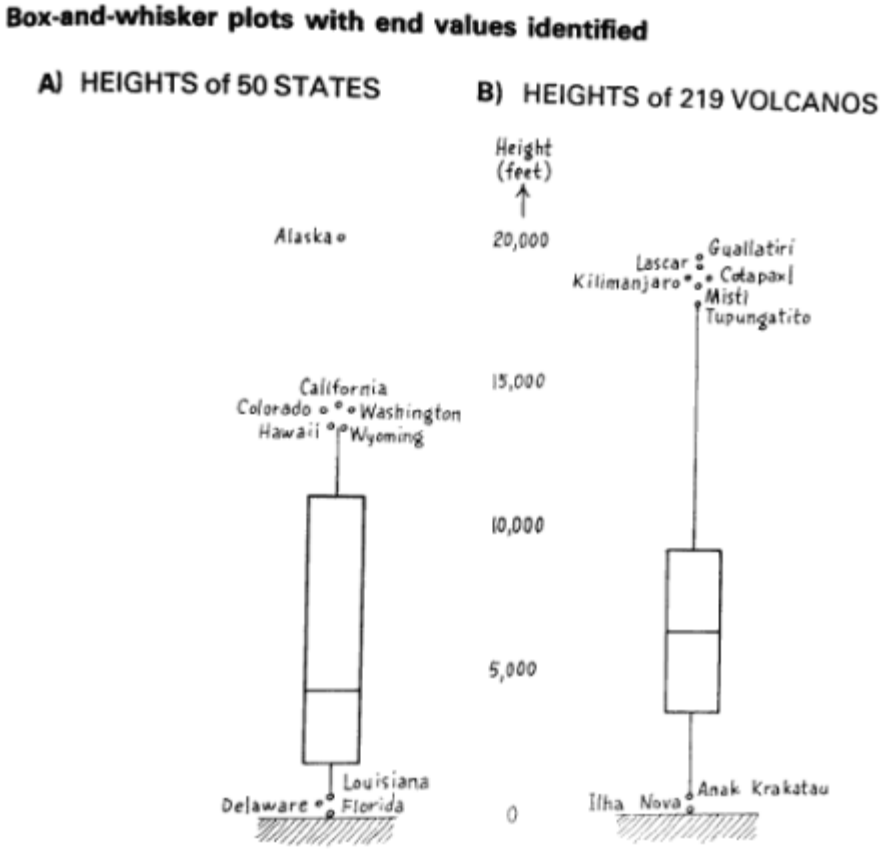


Gráfico de caja y bigotes de John W. Tukey comparando los puntos más altos de cada estado de EEUU y altitudes de algunos volcanes, 1977

Fuente: Michael Friendly,2007. A Brief History of Data Visualization. In Handbook of Computational Statistics: Data Visualization. III. Springer-Verlag. Heidelberg. 1-34.

Integración y validación de claves

Validación básica de claves

```
base = fuente1.merge(
    fuente2,
    on="id_estudiante",
    how="outer",
    indicator=True
)

base["_merge"].value_counts()
```

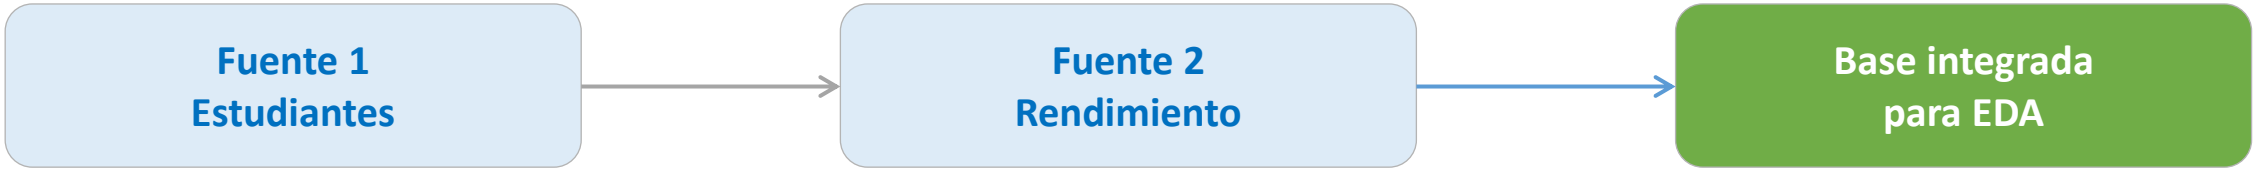
Resultado	Interpretación
both	Cruza en ambas fuentes
left_only	Solo aparece en fuente 1
right_only	Solo aparece en fuente 2

También revisar duplicados:

```
fuente1.duplicated(subset=["id_estudiante"], keep=False)
fuente2.duplicated(subset=["id_estudiante"], keep=False)
```

El objetivo no es “forzar” que todo cruce, sino entender qué registros quedaron fuera y si eso afecta el análisis.

Base integrada como punto de partida para el análisis



Antes de hacer gráficos, validar:

- La unidad de análisis es consistente.
- No hay duplicados que distorsionen conteos.
- Los registros no cruzados fueron revisados.
- Las variables clave tienen significado claro.

¿La base integrada representa correctamente aquello que quiero analizar?

Seleccionar el gráfico según la pregunta

Pregunta	Variables	Gráfico recomendado	Ejemplo
¿Cuántos casos hay por categoría?	Categórica	Barras px.bar()	Estudiantes por tipo de colegio
¿Cómo se distribuye una variable?	Numérica	Histograma / densidad px.histogram()	Distribución de nota final
¿Hay diferencias entre grupos?	Categórica + numérica	Boxplot px.box()	Nota según internet en casa
¿Hay relación entre variables?	Numérica + numérica	Dispersión px.scatter()	Horas de estudio vs. nota

Primero formule la pregunta; después elija el gráfico.



Primeras visualizaciones con Plotly Express

Plotly permite construir visualizaciones interactivas de forma rápida, facilitando la exploración, interpretación y comunicación de hallazgos en los datos.

Necesidad	Función
Histograma interactivo	px.histogram()
Boxplot interactivo	px.box()
Dispersión con detalles	px.scatter()
Barras	px.bar()

```
import plotly.express as px

fig = px.scatter(
    base, x="horas_estudio_semana", y="nota_final",
    color="resultado", size="asistencia_pct",
    hover_data=["id_estudiante", "tipo_colegio"]
)
fig.show()
```

Plotly ayuda a explorar: el gráfico permite ver detalles sin saturar la diapositiva.

De gráfico a hallazgo

Nivel	Pregunta	Ejemplo de redacción
Observación	¿Qué se ve?	Las notas parecen concentrarse entre 12 y 18.
Patrón	¿Se repite entre grupos?	Quienes tienen internet en casa muestran notas más altas.
Anomalía	¿Qué caso llama la atención?	Hay estudiantes con baja asistencia y nota aprobatoria.
Hipótesis	¿Qué podría explicar el patrón?	La asistencia y horas de estudio podrían estar asociadas al rendimiento.

Regla de oro

Un gráfico sin interpretación es solo una imagen. En una primera exploración, cada gráfico debe responder una pregunta o generar una hipótesis.

Checklist de integración



Unidad de análisis definida



Clave de unión validada



¿Sabemos qué registros cruzan y cuáles no?



¿La base integrada tiene sentido para responder las preguntas?



¿Los gráficos fueron elegidos según el tipo de variable?



¿Cada gráfico tiene una interpretación breve y prudente?

Integrar
Validar
Explorar
Interpretar

UNIVERSIDAD DEL PACÍFICO

¡Gracias por su atención!